

# Analiza Danych - Podstawy Statystyczne

Estymacja punktowa, przedziałowa i bayesowska

---

Marek Rupniewski

30 marca 2018



# Model parametryczny

$x_i$  to wynik  $i$ -tego pomiaru pewnej nieznanej wielkości  $x$  (pomiaru obarczone są pewnym losowym błędem).

Jak oszacować wartość  $x$ ?

Jak oszacować parametry błędu pomiaru (np. wariancję)?

Jak oszacować prawdopodobieństwo, że następny pomiar da wynik większy niż dotychczasowe?

itd.

Potrzebny model, np.  $X_i \sim N(x, \sigma^2)$ ,  $X_i$  niezależne zmienne losowe, a  $x_i$  to ich realizacje, czyli  $x_1, \dots, x_n$  to próba losowa z rozkładu  $N(x, \sigma^2)$ .

# Model parametryczny

$x_i$  to numer seryjny modułu, który trafia do serwisu  
( $i = 1, \dots, n$ ).

Jak oszacować ilość modułów na rynku?

Jak oszacować ilość modułów, które trafią do serwisu  
w przeciągu kolejnego miesiąca?

itd.

Zaczynamy analizę od konstrukcji modelu, np.  $x_i$  to realizacje  
niezależnych zmiennych

$$X_i \sim \text{Unif}([n_P, n_K]).$$

# Model parametryczny

W modelu parametrycznym mamy do czynienia z rodziną rozkładów

$$\mathcal{F} = \{F_\theta(x): \theta \in \Theta\}, \quad \Theta \subset \mathbb{R}^k,$$

gdzie

$$\theta = (\theta_1, \dots, \theta_k)$$

to parametr (rozkładu).

Zamiast dystrybuant  $F_\theta$  będziemy też rozważać funkcje prawdopodobieństwa lub funkcje gęstości prawdopodobieństwa  $f_\theta$ .

Czasami będziemy stosowali oznaczenia typu:

$$F(x; \theta), f(x; \theta), \dots$$

# Model parametryczny

Będziemy dalej zakładać, że mamy do dyspozycji próbę losową

$$X_1, \dots, X_n,$$

(ciąg **niezależnych zmiennych o tym samym rozkładzie**)  
z pewnego rozkładu  $F_\theta$  należącego do rodziny parametrycznej

$$\mathcal{F} = \{F_\theta(x) : \theta \in \Theta\}, \quad \Theta \subset \mathbb{R}^k.$$

Wartość parametru  $\theta \in \Theta$  nie jest znana!

Wszystkie zmienne  $X_1, \dots, X_n$  odpowiadają **tej samej** wartości  $\theta$ .

# Model parametryczny

Typowymi zagadnieniami rozważanymi w kontekście modeli parametrycznych są:

- wyznaczenie, na podstawie obserwacji (próby):  $X_1, \dots, X_n$ , nieznanego parametru  $\theta$ , tzn. wyznaczenie takiej funkcji (estymatora)

$$\hat{\theta} = \hat{\theta}(X_1, \dots, X_n),$$

która w jakimś sensie przybliża  $\theta$  (teoria estymacji).

- sprawdzenie, na podstawie obserwacji:  $X_1, \dots, X_n$ , czy  $\theta$  spełnia pewne warunki, np.

$$\theta = \theta_1, \quad \theta > \theta_1, \quad \theta \neq \theta_1$$

(testowanie hipotez statystycznych).

$$\mathcal{F} = \{f_p(x): p \in [0, 1]\} \quad (\theta = p).$$


$$f_p(x) = \begin{cases} p & x = 1, \\ 1 - p & x = 0. \end{cases}$$

Próba losowa  $X_1, \dots, X_N$  z rozkładu z rodziny  $\mathcal{F}$  może modelować  $N$  niezależnych rzutów tą samą monetą, o której nie wiemy jak bardzo jest niesymetryczna.

# Model parametryczny — przykłady

$$\mathcal{F} = \{f_\lambda(x) : \lambda > 0\} \quad (\theta = \lambda).$$

$$f_\lambda(x) = \frac{\lambda^x}{x!} e^{-\lambda}, \quad x \in \mathbb{N} = \{0, 1, 2, \dots\}.$$






# Rodzina rozkładów normalnych

$$\mathcal{F} = \{f_{(\mu, \sigma^2)}(x) : \mu \in \mathbb{R}, \sigma^2 > 0\} \quad \theta = (\mu, \sigma^2).$$

$$f_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$



# Rodzina rozkładów gamma

$$f_{\alpha,\beta}(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}, \quad x > 0, \alpha, \beta > 0,$$

gdzie


$$\Gamma(\alpha) = \int_0^\infty u^{\alpha-1} e^{-u} du, \quad \alpha > 0.$$

$$\Gamma(x+1) = x\Gamma(x) \quad x > 0, \quad \Gamma(1) = 1, \quad \Gamma(n+1) = n! \quad n \in \mathbb{N}.$$

Dla  $\alpha = 1$  otrzymujemy rozkład  $\text{Exp}(\frac{1}{\beta})$ .

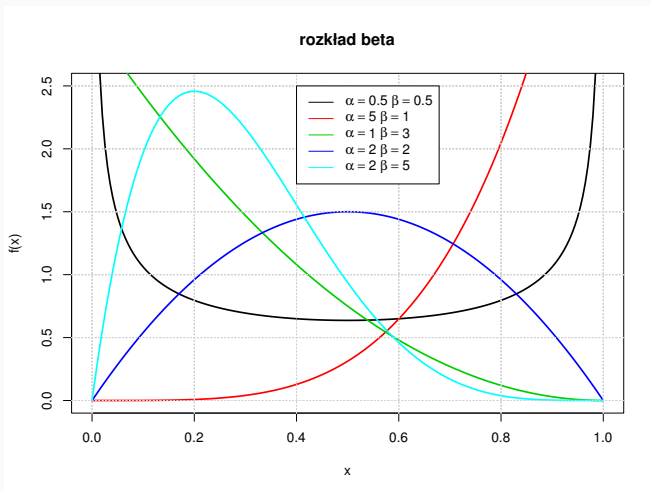
Uwaga! Czasami zamiast parametru skali  $\beta$  używa się parametru  $\frac{1}{\beta}$ .

# Rozkład Gamma — przykłady



# Rozkład beta

$$f_{\alpha,\beta}(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad x \in [0, 1], \alpha, \beta > 0$$



Powody mogą być dwojakie:

- wiemy skądinąd, że nasz model jest właściwy, lecz ta „zewnętrzna” wiedza nie daje nam informacji jakie jest  $\theta$ ,
- nie wiemy, że model jest właściwy, ale chcemy w jakiś zwarty sposób opisać pewną „rzeczywistość”.

# Metoda momentów

Rozważmy rodzinę

$$\{N(\mu, \sigma^2): \mu \in \mathbb{R}, \sigma > 0\}, \quad \theta = (\mu, \sigma^2).$$

oraz  $n$ -elementową próbę  $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ .

Chcemy na podstawie tej próby wyznaczyć nieznanne  $\mu, \sigma$ .

Zgodnie z prawem wielkich liczb mamy

$$\overline{X}_n \xrightarrow{\mathbb{P}} \mathbb{E}X_1 = \mu$$

oraz

$$\overline{(X^2)}_n = \frac{X_1^2 + \dots + X_n^2}{n} \xrightarrow{\mathbb{P}} \mathbb{E}X_1^2 = \mathbb{V}(X_1) + (\mathbb{E}X_1)^2 = \sigma^2 + \mu^2.$$

Za estymatory parametrów  $\mu, \sigma$  możemy zatem przyjąć, odpowiednio,

$$\hat{\mu} = \overline{X}_n, \quad \hat{\sigma} = \sqrt{\overline{(X^2)}_n - (\overline{X}_n)^2}.$$

## Definicja

Momentem  $k$ -tego rzędu zmiennej losowej  $X$  nazywamy liczbę

$$\mu_k = \mathbb{E} X^k.$$

## Definicja

Momentem  $k$ -tego rzędu z próby  $X_1, \dots, X_n$  nazywamy zmienną losową

$$m_k = \frac{1}{n} \sum_{i=1}^n X_i^k = \overline{(X^k)}_n.$$

# Metoda momentów

## Definicja

Estymator metody momentów dla parametru

$\theta = (\theta_1, \dots, \theta_k) \in \mathbb{R}^k$  i próby losowej  $X_1, \dots, X_n$ , to taka statystyka (funkcja próby, a więc zmienna losowa!)

$\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ , która „podstawiona w miejsce parametru  $\theta$ ” daje wybrane momenty rozkładu równe odpowiednim momentom z próby (np.  $\mu_1 = m_1$ ,  $\mu_2 = m_2$  i  $\mu_4 = m_4$ ).

Próba losowa  $X_1, \dots, X_n$  — estymator  $\hat{\theta}(X_1, \dots, X_n)$  (zmienna losowa).

Wartości próby  $x_1, \dots, x_n$  — wartość estymatora  $\hat{\theta}(x_1, \dots, x_n)$  (liczba, wektor liczbowy).



$$X_1, \dots, X_n \sim \text{Bern}(p).$$

$$\mu_1 = \mathbb{E}X = p.$$

$$m_1 = \frac{1}{n} \sum_{i=1}^n X_i.$$

Zatem estymatorem m. m. parametru  $p$  jest

$$\hat{p} = m_1 = \frac{1}{n} \sum_{i=1}^n X_i = \overline{X}_n.$$

$$X_1, \dots, X_n \sim \text{Pois}(\lambda).$$

$$\mu_1 = \lambda.$$

Zatem estymatorem m. m. parametru  $\lambda$  jest średnia z próby:

$$\hat{\lambda} = m_1.$$

## Metoda momentów — przykład (Bortkiewicz, 1898)

Analizowana była liczba zgonów od kopnięcia konia dla 10 korpusów pruskiej kawalerii w przeciągu 20-letniego okresu (mamy 200 „korpuso-lat”).

liczba zgonów/rok	liczba „korpuso-lat”
0	109
1	65
2	22
3	3
4	1

Próbujemy „dopasować” rozkład  $\text{Pois}(\lambda)$ .

$$\hat{\lambda} = (109 \times 0 + 65 \times 1 + 22 \times 2 + 3 \times 3 + 1 \times 4) / 200 = 0.61$$

# Metoda momentów

zgonów/rok	„korpuso-lat”	częstość	$P_{\hat{\lambda}}$	„k-l” wg $\hat{\lambda}$
0	109	0.545	0.543	109
1	65	0.325	0.331	66
2	22	0.110	0.101	20
3	3	0.015	0.021	4
4	1	0.005	0.003	1

# Metoda momentów

$$X_1, \dots, X_n \sim \text{Gamma}(\alpha, \beta).$$

$$\mu_1 = \alpha\beta, \quad \mu_2 = \alpha(\alpha + 1)\beta^2.$$

Wyznaczamy parametry w funkcji momentów:

$$\mu_2 = \mu_1^2 + \mu_1\beta \implies \beta = \frac{\mu_2 - \mu_1^2}{\mu_1}, \quad \alpha = \frac{\mu_1}{\beta} = \frac{\mu_1^2}{\mu_2 - \mu_1^2}.$$

Estymatorami m. m. parametrów  $\alpha, \beta$  są

$$\hat{\alpha} = \frac{m_1^2}{m_2 - m_1^2}, \quad \hat{\beta} = \frac{m_2 - m_1^2}{m_1}.$$

# Zgodność estymatorów metody momentów

$X_1, \dots, X_n$  próba losowa z rozkładu z parametrem  $\theta = (\theta_1, \dots, \theta_k)$ .

$$(\mu_1, \dots, \mu_k) = g(\theta_1, \dots, \theta_k) = g(\theta) = (g_1(\theta), \dots, g_k(\theta)).$$

$$\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_k) = g^{-1}(m_1, \dots, m_k).$$

Zmieniając licznosc próby  $n = 1, 2, \dots$  dostajemy ciąg estymatorów:

$$\hat{\theta}_{(1)}, \hat{\theta}_{(2)}, \dots, \hat{\theta}_{(n)}, \dots$$

## Twierdzenie

Estymator m. m. dla parametru  $\theta$  wyznaczony j.w. jest **zgodny**, tzn.

$$\hat{\theta}_{(n)} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta.$$

## Zgodność estymatora — przykład

$$\mathcal{F} = \{\text{Exp}(\lambda): \lambda > 0\}$$

$$h = \text{id}, \quad m(\lambda) = 1/\lambda = \mu_1(\lambda), \quad \hat{\lambda}_n = 1/\overline{X}_n$$

np.  $\lambda = 2$ ,  $\forall \epsilon \mathbb{P}(|\hat{\lambda}_n - 2| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$ , weźmy np.  $\epsilon_0 = 0.01$

$$\mathbb{P}(|\hat{\lambda}_{10} - 2| > \epsilon_0) \approx 0.99,$$

$$\mathbb{P}(|\hat{\lambda}_{100} - 2| > \epsilon_0) \approx 0.96,$$

$$\mathbb{P}(|\hat{\lambda}_{1000} - 2| > \epsilon_0) \approx 0.87,$$

$$\mathbb{P}(|\hat{\lambda}_{10000} - 2| > \epsilon_0) \approx 0.62,$$

$$\mathbb{P}(|\hat{\lambda}_{100000} - 2| > \epsilon_0) \approx 0.11,$$

$$\mathbb{P}(|\hat{\lambda}_{200000} - 2| > \epsilon_0) \approx 0.03,$$

# Asymptotyczna normalność estymatorów m. m.

$$\theta = (\theta_1, \dots, \theta_k), \hat{\theta}_{(n)} = (\hat{\theta}_1, \dots, \hat{\theta}_k) = g^{-1}(m_1, \dots, m_k).$$

## Twierdzenie

Estymator m. m. dla parametru  $\theta$  wyznaczony j.w. jest *asymptotycznie normalny*, tzn.

$$\sqrt{n}(\hat{\theta}_{(n)} - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, \Sigma),$$

W przypadku skalarnym mamy

$$\sqrt{n}(\hat{\theta}_{(n)} - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, \sigma^2),$$

$$\sigma^2 = \frac{g_2(\theta)}{(g_1'(\theta))^2} = \frac{\mu_2(\theta)}{\left(\frac{\partial \mu_1(\theta)}{\partial \theta}\right)^2}.$$



## Asymptotyczna normalność — przykład


$$\mathcal{F} = \{\text{Exp}(\lambda): \lambda > 0\}$$

$$h = \text{id}, \quad m(\lambda) = 1/\lambda = \mu_1(\lambda), \quad \hat{\lambda}_n = 1/\bar{X}_n$$

Asymptotyczna normalność estymatora  $\hat{\lambda}_n$  oznacza punktową zbieżność dystrybuant  $F_n$  zmiennych  $Y_n = \sqrt{n}(\hat{\lambda}_n - \lambda)$  do dystrybuanty  $F$  rozkładu  $N(0, \lambda^2)$ , t.j.

$$\forall t \in \mathbb{R} \quad F_n(t) \xrightarrow{n \rightarrow \infty} F(t).$$

# Asymptotyczna normalność — ilustracja przykładu



# Estymatory największej wiarygodności

---

$$\mathcal{F} = \{f_\theta(x) : \theta \in \Theta\}, \quad \Theta \subset \mathbb{R}^k,$$

$X_1, \dots, X_n$  próba losowa (niezależne zmienne losowe o tym samym rozkładzie) z rozkładu odpowiadającemu pewnej wartości  $\theta$ .

### Definicja (Funkcja wiarygodności)

Funkcja wiarygodności  $\mathcal{L}_n$  to funkcja określona formułą

$$\mathcal{L}_n(\theta) = \mathcal{L}_n(x_1, \dots, x_n; \theta) = f_\theta(x_1) \times \dots \times f_\theta(x_n).$$

Logarytmiczna funkcja wiarygodności  $\ell_n$  to

$$\ell_n(\theta) = \ell_n(x_1, \dots, x_n; \theta) = \ln(\mathcal{L}_n(\theta)).$$

$$\mathcal{F} = \{f_\theta(x): \theta \in \Theta\}, \quad \Theta \subset \mathbb{R}^k,$$

$X_1, \dots, X_n$  próba losowa z rozkładu odpowiadającemu pewnej (nieznanej) wartości  $\theta$ .

## Definicja

Estymator największej wiarygodności  $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$  parametru  $\theta$  to zmienna losowa maksymalizująca funkcję wiarygodności  $\mathcal{L}_n$ , czyli

$$\hat{\theta}_n = \arg \max_{\theta} \mathcal{L}_n(X_1, \dots, X_n; \theta).$$

Równoważnie

$$\hat{\theta}_n = \arg \max_{\theta} \ell_n(X_1, \dots, X_n; \theta).$$

## Estymator n. w. dla rozkładu Bern( $p$ )

$$\mathcal{F} = \{f_p(x): p \in [0, 1]\}, \quad f_p(1) = p, f_p(0) = 1 - p.$$

Dla zwartości zapisu  $\mathcal{L}_n(p)$  zamiast  $\mathcal{L}_n(X_1, \dots, X_n; p)$ .

$$\begin{aligned}\mathcal{L}_n(p) &= f_p(X_1) \times \dots \times f_p(X_n) = p^{\text{liczba } 1} (1-p)^{\text{liczba } 0} \\ &= p^{X_1 + \dots + X_n} (1-p)^{n - (X_1 + \dots + X_n)}.\end{aligned}$$

$$\ell_n(p) = (X_1 + \dots + X_n) \ln p + (n - (X_1 + \dots + X_n)) \ln(1-p).$$

$$\frac{d\ell_n(p)}{dp} = \frac{X_1 + \dots + X_n}{p} - \frac{n - (X_1 + \dots + X_n)}{1-p}.$$

$$\hat{p}_n = \frac{X_1 + \dots + X_n}{n} = \overline{X}_n = m_1.$$

## Estymator n. w. dla rozkładu $N(\mu, \sigma^2)$

$$\mathcal{F} = \{f_{\mu, \sigma^2}(x) : (\mu, \sigma^2) \in \mathbb{R} \times (0, \infty)\},$$

$$f_{\mu, \sigma^2}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

Logarytmiczna funkcja wiarygodności

$$\ell_n(\mu, \sigma^2) = -n \ln \sqrt{2\pi} - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2.$$

$$\frac{\partial \ell_n(\mu, \sigma^2)}{\partial \mu} = 0 \implies \hat{\mu} = \overline{X}_n.$$

$$\frac{\partial \ell_n(\mu, \sigma^2)}{\partial \sigma^2} = 0 \implies \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2.$$

## Estymator n. w. dla rozkładu $\text{Unif}([0, \theta])$

$$\mathcal{F} = \{f_\theta(x): \theta > 0\}, \quad f_\theta(x) = \begin{cases} \frac{1}{\theta} & \text{dla } x \in [0, \theta] \\ 0 & \text{w p.p.} \end{cases}$$

Funkcja wiarygodności

$$\mathcal{L}_n(\theta) = \frac{1}{\theta^n} \mathbb{1}_{[0, \theta]} \left( \max(X_1, \dots, X_n) \right).$$

$$\hat{\theta}_n = \max(X_1, \dots, X_n) = X_{(n)}.$$

Metoda momentów daje w tym wypadku

$$\hat{\theta}_n = 2\overline{X}_n.$$



## Estymator n. w. dla rozkładu $\Gamma$

$$\mathcal{F} = \{f_{\alpha,\beta}(x) : (\alpha, \beta) \in (0, \infty) \times (0, \infty)\},$$

$$f_{\alpha,\beta}(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta},$$

$$\Gamma(\alpha) = \int_0^\infty u^{\alpha-1} e^{-u} du, \quad \alpha > 0.$$

Logarytmiczna funkcja wiarygodności:

$$\ell_n(\alpha, \beta) = (\alpha - 1) \sum_{k=1}^n \ln X_k - \sum_{k=1}^n X_k / \beta - n\alpha \ln \beta - n \ln \Gamma(\alpha).$$

$$\frac{\partial \ell_n}{\partial \beta} = 0 \implies \hat{\beta} = \frac{\overline{X}_n}{\hat{\alpha}}.$$

$$\frac{\partial \ell_n}{\partial \alpha} = 0 \implies \overline{(\ln X)}_n - \ln \overline{X}_n = \frac{\Gamma'(\hat{\alpha})}{\Gamma(\hat{\alpha})} - \ln \hat{\alpha}.$$

Powyższe równanie rozwiązuje się numerycznie ...

## Definicja

Obciążenie estymatora  $\hat{\theta}_n$  parametru  $\theta$  to wielkość

$$\mathbb{E}\hat{\theta} - \theta.$$

Estymator  $\hat{\theta}_n$  parametru  $\theta$  nazywany jest **estymatorem nieobciążonym**, jeśli jego obciążenie jest zerowe, czyli

$$\mathbb{E}\hat{\theta} = \theta.$$

Przykład:  $\mathcal{F} = \{\text{Unif}([0, \theta]): \theta > 0\}$

Estymator (parametru  $\theta$ ) m. m. jest nieobciążony:

$$\mathbb{E}\hat{\theta}_n = \mathbb{E}(2\bar{X}_n) = \frac{2}{n}\mathbb{E}(X_1 + \dots + X_n) = \frac{2}{n}n\frac{\theta}{2} = \theta.$$

Estymator (parametru  $\theta$ ) n. w. jest obciążony:

$$\mathbb{E}\hat{\theta}_n = \mathbb{E}(\max(X_1, \dots, X_n)) < \theta.$$

# Własności estymatorów największej wiarygodności

## Twierdzenie

Estymator  $n. w.$  dla parametru  $\theta$  (przy pewnych założeniach co do regularności modelu) jest

- **zgodny**, tzn.

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta,$$

- **asymptotycznie normalny**, tzn. (przypadek skalarne go parametru)

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, \sigma_{MLE}^2),$$

- **ekwiwariantny**, tzn. jeśli  $\hat{\theta}_n$  jest estymatorem  $n. w.$  dla  $\theta$ , to  $g(\hat{\theta}_n)$  jest estymatorem  $n. w.$  dla  $g(\theta)$ .
- **asymptotycznie optymalny** (asymptotycznie efektywny)

# Funkcja informacji Fishera

$$\mathcal{F} = \{f_\theta(x) : \theta \in \Theta\}, \quad \Theta \subset \mathbb{R}^k,$$

$X_\theta$  zmienna losowa o rozkładzie zadany fun. gęst.  $f_\theta(x)$ .

## Definicja (Funkcja informacji Fishera)

Funkcją informacji Fishera (informacją Fishera) dla rodziny  $\mathcal{F}$  ze skalarnym ( $k = 1$ ) parametrem  $\theta$  nazywamy odwzorowanie

$$\Theta \ni \theta \mapsto I(\theta) = \mathbb{E} \left( \ell'(\theta) \right)^2 = \mathbb{E} \left( \frac{\partial \ln f_\theta(X_\theta)}{\partial \theta} \right)^2 = \mathbb{E} \left( \frac{f'_\theta(X_\theta)}{f_\theta(X_\theta)} \right)^2.$$

W przypadku wektorowego parametru  $\theta$  ( $k > 1$ )  $I(\theta)$  jest macierzą o  $i, j$ -tym elemencie określonym formułą

$$\mathbb{E} \left( \frac{\partial \ell(\theta)}{\partial \theta_i} \frac{\partial \ell(\theta)}{\partial \theta_j} \right).$$

$$I(\theta) = \mathbb{E} \left( \ell'(\theta) \right)^2.$$

## Fakt

*Przy pewnych założeniach co do regularności modelu*

$$\mathbb{E} \left( \ell''(\theta) \right) = \mathbb{E} \left( \frac{\partial^2 \ln f_{\theta}(X_{\theta})}{\partial \theta^2} \right) = -I(\theta).$$

## Twierdzenie (Asymptotyczna normalność est. n. w.)

Jeśli  $\hat{\theta}_n$  jest estymatorem n. w., to

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow \infty]{d} N\left(0, \frac{1}{I(\theta)}\right).$$

Równoważnie:

$$\sqrt{nI(\theta)}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, 1).$$

Co więcej

$$\sqrt{nI(\hat{\theta})}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow \infty]{d} N(0, 1).$$

# Rozkład Bern( $p$ )

Funkcja gęstości prawdopodobieństwa

$$f_p(x) = p\mathbb{1}_{\{1\}}(x) + (1-p)\mathbb{1}_{\{0\}}(x) = p^x(1-p)^{1-x}.$$

$$\ell'(p) = (x \ln p + (1-x) \ln(1-p))' = \frac{x}{p} - \frac{1-x}{1-p}.$$

$$\ell''(p) = -\frac{x}{p^2} - \frac{1-x}{(1-p)^2}.$$

$$I(p) = -\mathbb{E}\ell''(p) = \frac{\mathbb{E}X}{p^2} + \frac{1-\mathbb{E}X}{(1-p)^2} = \frac{1}{p} + \frac{1}{1-p} = \frac{1}{p(1-p)}.$$

Funkcja gęstości prawdopodobieństwa

$$f_{\lambda}(x) = \lambda e^{-\lambda x} \quad \text{dla } x \geq 0.$$

$$\ell(\lambda) = \ln \lambda - \lambda x, \quad \ell''(\lambda) = -\frac{1}{\lambda^2}.$$

$$I(\lambda) = -\mathbb{E} \left( -\frac{1}{\lambda^2} \right) = \frac{1}{\lambda^2}.$$



# Rozkład Pois( $\lambda$ )

Funkcja gęstości prawdopodobieństwa

$$f_{\lambda}(x) = \frac{\lambda^x}{x!} e^{-\lambda} \quad x = 0, 1, \dots$$

$$\ell(\lambda) = x \ln \lambda - \lambda - \ln x!, \quad \ell''(\lambda) = -\frac{x}{\lambda^2}.$$

$$I(\lambda) = -\mathbb{E} \left( -\frac{X}{\lambda^2} \right) = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda}.$$

# Nierówność Crámera-Rao

Niech  $X_1, \dots, X_n$  próba losowa (zmienne niezależne o tym samym rozkładzie odpowiadającym nieznaney wartości parametru  $\theta$ ),  $S = S(X_1, \dots, X_n)$  statystyka oraz

$$m(\theta) = \mathbb{E}S(X_1, \dots, X_n).$$

## Twierdzenie (Crámera-Rao)

$$\mathbb{V}(S) = \mathbb{E}(S - m(\theta))^2 \geq \frac{(m'(\theta))^2}{nI(\theta)},$$

przy czym równość wtw, gdy

$$S(X_1, \dots, X_n) = m(\theta) + t(\theta)\ell'_n(X_1, \dots, X_n; \theta),$$

dla pewnej funkcji  $t(\theta)$ .

## Definicja

Niech  $S = S(X_1, \dots, X_n)$  będzie statystyką oraz  $m(\theta) = \mathbb{E}S$ .  
 $S$  nazywamy **efektywnym estymatorem** wielkości  $m(\theta)$ , jeśli

$$\mathbb{E}(S - m(\theta))^2 = \frac{(m'(\theta))^2}{nI(\theta)},$$

tzn. w nierówności Crámera-Rao zachodzi równość.

Estymator efektywny wielkości  $m(\theta)$  nie musi istnieć!

Niech  $\hat{\theta}$  będzie nieobciążonym ( $\mathbb{E}\hat{\theta} = \theta$ ) estymatorem największej wiarygodności. Z nierówności Crámera-Rao wiadomo, że

$$\mathbb{V}(\hat{\theta}) \geq \frac{1}{nI(\theta)}, \text{ czyli } n\mathbb{V}(\hat{\theta}) \geq \frac{1}{I(\theta)}.$$

Wiemy również, że

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow[n \rightarrow \infty]{d} N\left(0, \frac{1}{I(\theta)}\right).$$

Stąd

$$\mathbb{V}(\sqrt{n}(\hat{\theta} - \theta)) = n\mathbb{V}(\hat{\theta}) \rightarrow \frac{1}{I(\theta)}.$$

Ta własność nazywa się **asymptotyczną efektywnością** estymatorów największej wiarygodności.

# Przedziały ufności

---

# Przedziały ufności

$X_1, \dots, X_n$  próba losowa odp. pewnej (nieznanej) wartości parametru  $\theta \in \Theta$ .

## Definicja

Losowy przedział

$$\left[ A(X_1, \dots, X_n), B(X_1, \dots, X_n) \right]$$

nazywamy **przedziałem ufności na poziomie ufności  $\gamma$**  dla parametru  $\theta$ , jeśli dla każdego  $\theta \in \Theta$  zachodzi nierówność

$$\mathbb{P} \left( \theta \in \left[ A(X_1, \dots, X_n), B(X_1, \dots, X_n) \right] \right) \geq \gamma.$$

Poziom ufności wyraża się często przez  $1 - \alpha$  zamiast  $\gamma$ .

Przedziały ufności dla estymatora można wyznaczać:

- W sposób dokładny wykorzystując znajomość (jeśli się ją ma) analitycznej postaci rozkładu estymatora,
- W sposób przybliżony wykorzystując graniczny (normalny) rozkład estymatora,
- W sposób przybliżony przez symulacje (tzw. bootstrapping).

# Wyznaczanie przedziału uf. z wykorzystaniem rozkładu granicznego

Ilość zgonów od kopnięcia konia dla 10 korpusów pruskiej kawalerii była zebrana z 20-letniego okresu (mamy 200 „korpuso-lat”).



## Wyznaczanie przedziału uf. z wykorzystaniem rozkładu granicznego

ilość zgonów/rok	0	1	2	3	4
liczba „korpuso-lat”	109	65	22	3	1

$$\hat{\lambda} = (109 \times 0 + 65 \times 1 + 22 \times 2 + 3 \times 3 + 1 \times 4) / 200 = 0.61$$

$$\sqrt{n}(\hat{\lambda} - \lambda) \approx N(0, 1/I(\hat{\lambda})) = N(0, \hat{\lambda}) = \sqrt{\hat{\lambda}}N(0, 1)$$

Przedział ufności dla  $\lambda$  na poziomie ufności  $\gamma = 1 - \alpha$  można zatem przybliżyć jako

$$\begin{aligned} & \left[ \hat{\lambda} - z_{(1+\gamma)/2} \sqrt{\hat{\lambda}/n}, \hat{\lambda} + z_{(1+\gamma)/2} \sqrt{\hat{\lambda}/n} \right] \\ &= \left[ \hat{\lambda} - z_{1-\frac{\alpha}{2}} \sqrt{\hat{\lambda}/n}, \hat{\lambda} + z_{1-\frac{\alpha}{2}} \sqrt{\hat{\lambda}/n} \right] \stackrel{\gamma=0.95}{\approx} [0.50, 0.72]. \end{aligned}$$

# Bootstrap parametryczny

- Mamy do dyspozycji próbę, na podstawie której estymujemy parametr rozkładu  $\hat{\theta}$ . Chcemy zbadać jakie są własności (np. wariancja, kwantyle, rozkład) tego estymatora lub innej statystyki.
- Nie dysponując dodatkowymi danymi próbujemy wykorzystać to co mamy (bootstrapping).
- W przypadku modelu parametrycznego generujemy wiele losowych prób (liczności takiej jak oryginalna próba), dla każdej z nich wyznaczamy wartość badanej statystyki i badamy rozkład/wariancję/kwantyle/itp. tych wartości. Żeby wygenerować próby musimy znać parametr  $\theta$  rozkładu!

Zamiast  $\theta$  wykorzystujemy (istota bootstrapu parametrycznego) estymatę  $\hat{\theta}$  uzyskaną na podstawie oryginalnych danych.

## Wyznaczanie przedziału uf. metodą bootstrapu parametrycznego

ilość zgonów/rok	0	1	2	3	4
liczba „korpuso-lat”	109	65	22	3	1

$$\hat{\lambda} = 0.61$$

Generujemy  $N \gg 1$  zestawów po  $n = 200$  liczb z rozkładu  $\text{Pois}(\hat{\lambda})$ . Dla każdego zestawu wyliczamy wartość estymatora. Wyznaczamy przedział ufności  $[A, B]$  (na poziomie ufności  $\gamma$ ) tak, aby obejmował  $\gamma \times N$  spośród wyznaczonych  $N$  wartości estymatora. Dla  $\gamma = 0.95$ ,  $N = 1000$ ,  $\hat{\lambda} = 0.61$  w wyniku symulacji otrzymujemy

$$[A, B] \approx [0.45, 0.77].$$

# Bootstrap nieparametryczny

- Mamy do dyspozycji próbę, na podstawie której wyznaczamy pewną statystkę  $T$ . Chcemy zbadać jakie są własności tej statystyki.
- W przypadku braku modelu parametrycznego generujemy wiele losowych prób (liczności takiej jak oryginalna próba) „z tego samego rozkładu co wyjściowa próba”. Dla każdej wygenerowanej próby wyznaczamy wartość statystyki  $T$ , a następnie badamy rozkład/wariancję/kwantyle/itp. tych wartości.
- Żeby wygenerować próby musimy znać rozkład! Za (nieznany!) rozkład przyjmujemy rozkład o dystrybuancie równej dystrybuancie (empirycznej) uzyskanej z wyjściowej próby!

# Rozkład Normalny (Gaussa) — przypomnienie

$X$  ma rozkład normalny (Gaussa) z parametrami  $\mu, \sigma$ ,  
 $X \sim N(\mu, \sigma^2)$ , jeśli

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R}.$$

Funkcję gęstości oraz dystrybuantę zmiennej o rozkładzie  $N(0, 1)$  oznacza się, odpowiednio, literami  $\phi$  oraz  $\Phi$ . Kwantyl rzędu  $\alpha$  dla rozkładu  $N(0, 1)$  oznacza się zazwyczaj przez  $z_\alpha$ .

## Estymacja $\mu$ , znane $\sigma^2$

$$X_k = \mu + \epsilon_k, \quad k = 1, \dots, n,$$

$\epsilon_1, \dots, \epsilon_n$  niezależne zmienne losowe  $\sim N(0, \sigma^2)$ .

$X_k$  mogą modelować pomiary badanej wielkości  $\mu$ , gdzie błąd pomiaru (np. związany z przyrządem) ma rozkład  $N(0, \sigma^2)$ .

Mamy do czynienia z rodziną (parametryczną):

$$\mathcal{F} = \left\{ \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} : \mu \in \mathbb{R} \right\}, \quad \sigma^2 \text{ ustalone.}$$

$\bar{X}_n$  jest efektywnym estymatorem  $\mu$ . Jego wariancja, to

$$\mathbb{V}(\bar{X}_n) = \frac{1}{nI(\mu)} = \frac{\sigma^2}{n}.$$

## Przedziały ufności dla $\mu$ gdy $\sigma^2$ **znane**

$$\hat{\mu} = \overline{X}_n$$

Estymator  $\hat{\mu} = \overline{X}_n$  ma rozkład

$$N\left(\mu, \frac{\sigma^2}{n}\right).$$

Przedziałem ufności dla  $\mu$  na poziomie ufności  $\gamma = 1 - \alpha$  jest zatem

$$\begin{aligned} & \left[ \overline{X} - \frac{\sigma}{\sqrt{n}} z_{(1+\gamma)/2}, \overline{X} + \frac{\sigma}{\sqrt{n}} z_{(1+\gamma)/2} \right] \\ &= \left[ \overline{X} - \frac{\sigma}{\sqrt{n}} z_{1-\alpha/2}, \overline{X} + \frac{\sigma}{\sqrt{n}} z_{1-\alpha/2} \right]. \end{aligned}$$

Przypadkiem gdy  $\sigma^2$  nie jest znane zajmiemy się za chwilę...

## Estymacja $\sigma^2$ , znane $\mu$

$X_k = \mu + \epsilon_k$ ,  $k = 1, \dots, n$ ,  $\epsilon_1, \dots, \epsilon_n$  niezależne  $\sim N(0, \sigma^2)$ .

$X_k$  mogą modelować pomiary znanej wielkości (wzorca)  $\mu$ , gdzie błąd pomiaru (np. związany z przyrządem) ma rozkład  $N(0, \sigma^2)$ .

Mamy do czynienia z rodziną (parametryczną):

$$\mathcal{F} = \left\{ \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} : \sigma^2 > 0 \right\}, \quad \mu \text{ znane.}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

jest efektywnym estymatorem dla  $\sigma^2$  z wariancją

$$\mathbb{V}(\hat{\sigma}^2) = 1/(nI(\sigma^2)) = 2\sigma^4/n.$$




## Definicja

Niech  $X_1, \dots, X_n$  niezależne zmienne losowe o rozkładzie  $N(0, 1)$ . Rozkładam  $\chi^2$  o  $n$  stopniach swobody (rozkładem  $\chi_n^2$ ) nazywamy rozkład zmiennej losowej

$$X_1^2 + \dots + X_n^2.$$

$$\chi_n^2 = \text{Gamma}\left(\frac{n}{2}, 2\right).$$

# Rozkład $\chi^2$ — wykresy funkcji gęstości



## Przedziały ufności dla $\sigma^2$ ( $\mu$ znane)

$X_k \sim N(\mu, \sigma^2)$  niezależne,  $\mu$  znane.

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2.$$

$$\frac{n\hat{\sigma}^2}{\sigma^2} \text{ ma rozkład } \chi_n^2.$$

Przedziałem ufności dla  $\sigma^2$  na poziomie ufności  $\gamma$  jest zatem

$$\left[ \frac{n\hat{\sigma}^2}{F_{\chi_n^2}^{-1}(1-b)}, \frac{n\hat{\sigma}^2}{F_{\chi_n^2}^{-1}(a)} \right], \quad a, b \geq 0, a + b = 1 - \gamma.$$

Można wziąć np.  $a = b = (1 - \gamma)/2$ .

## Estymacja $\sigma^2$ , nieznanne $\mu$ i $\sigma^2$

$X_k = \mu + \epsilon_k$ ,  $k = 1, \dots, n$ ,  $\epsilon_1, \dots, \epsilon_n$  niezależne  $\sim N(0, \sigma^2)$ .

$X_k$  mogą modelować pomiary nieznannej wielkości (wzorca)  $\mu$ , gdzie błąd pomiaru (np. związany z przyrządem) ma rozkład  $N(0, \sigma^2)$  z nieznanymi odchyleniem standardowym  $\sigma$ .

Mamy do czynienia z rodziną (parametryczną):

$$\mathcal{F} = \left\{ e^{-\frac{(x-\mu)^2}{2\sigma^2}} / \sqrt{2\pi\sigma^2} : \mu \in \mathbb{R}, \sigma^2 > 0 \right\}.$$

Estymator  $\hat{\sigma}^2 = \frac{1}{n} \sum_{k=1}^n (X_k - \overline{X}_n)^2$  nie jest już estymatorem nieobciążonym. Nieobciążonym i asymptotycznie efektywnym estymatorem parametru  $\sigma^2$  jest za to

$$S_n^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \overline{X}_n)^2.$$

## Przedziały ufności dla $\mu$ oraz $\sigma^2$

$$S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X}_n)^2, \quad X_k \sim N(\mu, \sigma^2) \text{ niezależne.}$$

$$\frac{(n-1)S^2}{\sigma^2} \sim \text{Gamma}\left(\frac{n-1}{2}, 2\right) = \chi_{n-1}^2.$$

Przedziałem ufności dla  $\sigma^2$  na poziomie ufności  $\gamma$  jest zatem

$$\left[ \frac{(n-1)S^2}{F_{\chi_{n-1}^2}^{-1}(1-b)}, \frac{(n-1)S^2}{F_{\chi_{n-1}^2}^{-1}(a)} \right], \quad a, b \geq 0, a + b = 1 - \gamma.$$

Można wziąć np.  $a = b = (1 - \gamma)/2$ .

## Przedziały ufności dla $\mu$ , gdy $\sigma^2$ nieznane

$X_k \sim N(\mu, \sigma^2)$  niezależne.

$$\hat{\mu} = \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right) \text{ czyli } \frac{\sqrt{n}(\hat{\mu} - \mu)}{\sqrt{\sigma^2}} \sim N(0, 1).$$


Nie znamy  $\sigma^2$ ! Możemy za to rozważyć zmienną

$$t_{n-1} = \frac{\sqrt{n}(\hat{\mu} - \mu)}{\sqrt{S^2}}.$$

Rozkład tej zmiennej nazywany jest rozkładem Studenta (t-Studenta) o  $n-1$  stopniach swobody. Przedziałem ufności dla  $\mu$  na poziomie ufności  $\gamma$  jest zatem

$$\left[ \bar{X}_n - \frac{S}{\sqrt{n}} F_{t_{n-1}}^{-1} \left( \frac{1+\gamma}{2} \right), \bar{X}_n + \frac{S}{\sqrt{n}} F_{t_{n-1}}^{-1} \left( \frac{1+\gamma}{2} \right) \right].$$

# Rozkład t-Studenta — wykresy funkcji gęstości



# Estymacja w ujęciu bayesowskim

---



# Czym właściwie jest prawdopodobieństwo

- **prawdopodobieństwo obiektywne** nazywane także prawdopodobieństwem w sensie częstościowym. Jeśli prawdopodobieństwo (częstościowe) wyrzucenia orła pewną monetą wynosi  $\frac{1}{2}$ , to

$$\lim_{n \rightarrow \infty} \frac{\text{liczba orłów w pierwszych } n \text{ rzutach}}{n} = \frac{1}{2}.$$

- **prawdopodobieństwo subiektywne** nazywane także prawdopodobieństwem w sensie bayesowskim. W tym sensie prowadzący przedmiot może stwierdzić, że np. student A zaliczy przedmiot ADPS z prawdopodobieństwem 80%, a student B — z prawdopodobieństwem 99%. Studenci *A* i *B* mogą oceniać te prawdopodobieństwa inaczej. Co więcej, prawdopodobieństwa te mogą się zmieniać wraz z czasem (napływ nowych informacji).

# Prawdopodobieństwo bayesowskie

Prawdopodobieństwo bayesowskie spełnia wszystkie aksjomaty prawdopodobieństwa:

- $\mathbb{P}(A) \geq 0$  dla każdego zdarzenia  $A$ ,
- $\mathbb{P}(\Omega) = 1$ ,
- Dla każdych rozłącznych zdarzeń  $A_1, A_2, A_3, \dots$

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

# Prawdopodobieństwo warunkowe

W podejściu bayesowskim kluczową rolę gra prawdopodobieństwo warunkowe:

$\mathbb{P}(A)$ , to nasze przekonanie, że prawdziwe jest  $A$ .

W szczególnych przypadkach można interpretować  $\mathbb{P}(A)$  jako prawdopodobieństwo a priori (przed wykonaniem eksperymentu/pomiaru).

$\mathbb{P}(A|B)$ , to nasze przekonanie, że prawdziwe jest  $A$  pod warunkiem, że zachodzi  $B$ . Można je interpretować jako prawdopodobieństwo a posteriori (po wykonaniu eksperymentu/pomiaru, którego wynik opisywany jest przez  $B$ ).

$$\mathbb{P}(A|B) = \mathbb{P}(A \cap B) / \mathbb{P}(B).$$

$$\mathbb{P}(B|A) = \mathbb{P}(B \cap A) / \mathbb{P}(A) = \mathbb{P}(A|B) \mathbb{P}(B) / \mathbb{P}(A).$$

# Prawdopodobieństwo warunkowe a intuicja

Mamy do dyspozycji 3 monety:

1. monetę orzeł-reszka (O/R),
2. monetę orzeł-orzeł (O/O),
3. monetę reszka-reszka (R/R).

Losowo wybieramy monetę i rzucamy nią dostając orła. Jakie jest prawdopodobieństwo tego, że z drugiej strony jest też orzeł?

$$\frac{2}{3}$$

# Prawdopodobieństwo warunkowe a intuicja

W pewnej zabawie mamy do wyboru 3 drzwi. Za jednym z nich stoi samochód, który wygramy wybierając te drzwi. Za pozostałymi stoją kozy. Wybieramy jedno z drzwi (nie zaglądamy za nie), a następnie prowadzący zabawę otwiera jedno z pozostałych drzwi ukazując kozę. Następnie zadaje pytanie, czy zmieniamy nasz wybór. Zmienić wybór/ nie zmienić / wszystko jedno?

Zmienić wybór! (wygramy z prawd.  $\frac{2}{3}$ ; gdy nie zmienimy mamy szanse  $\frac{1}{3}$ ).

# Problemy z szacowaniem prawdopodobieństw warunkowych

Przed 100 lekarzami postawiono następujący problem dotyczący analizowania wyników mammograficznych badań przesiewowych:

- W przypadku braku pewnych dodatkowych informacji, prawdopodobieństwo, że kobieta (w odp. wieku i kondycji) ma raka piersi wynosi 1%.
- Jeśli pacjentka ma raka piersi, to prawdopodobieństwo, że radiolog na podstawie badania postawi właściwą diagnozę wynosi 80%.
- Jeśli pacjentka ma zmiany nienowotworowe, to prawdopodobieństwo, że radiolog zdiagnozuje raka wynosi 10%.

Jakie jest prawdopodobieństwo, że pacjentka z pozytywnym wynikiem mammografii ma istotnie raka piersi?

## Twierdzenie (Reguła Bayesa)

Jeśli  $A$  jest pewnym zdarzeniem oraz rozłączne zdarzenia  $B_1, \dots, B_n$  o niezerowym prawdopodobieństwie pokrywają całą przestrzeń probabilistyczną  $\Omega$  ( $\bigcup_{i=1}^n B_i = \Omega$ ), to

$$\mathbb{P}(B_j|A) = \frac{\mathbb{P}(A|B_j)\mathbb{P}(B_j)}{\sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i)}.$$

wersja „ciągła”:

$$f_{X|Y}(x|y) = \frac{f_{Y|X}(y|x)f_X(x)}{\int_{-\infty}^{+\infty} f_{Y|X}(y|x)f_X(x)dx}.$$

Parametryczny model:

$$\mathcal{F} = \{f_p(x): p \in \Theta\}, \quad \Theta \subset \mathbb{R}^k,$$

z parametrem  $p = (p_1, \dots, p_k)$

W podejściu **bayesowskim** zakładamy, że parametr  $p$  jest **zmienną losową!** (w związku z tym będziemy go czasem oznaczać dużą literą  $P$ ) o pewnym rozkładzie zadany np. funkcją prawdopodobieństwa:

- **a priori**

$$f_{\text{prior}} = f_P: \Theta \rightarrow \mathbb{R}, \quad p \mapsto f(p)$$

wynikającą z naszej wiedzy i doświadczenia,

- **a posteriori**

$$f_{\text{post}} = f_{P|X}: \Theta \times \mathbb{R}^n \rightarrow \mathbb{R}, \quad (p, x_1, \dots, x_n) \mapsto f_{\text{post}}(p, x_1, \dots, x_n)$$

wynikającą z rozkładu **a priori** oraz zaobserwowanej próby

$$X = (X_1, \dots, X_n).$$



# Konstrukcja rozkładu a posteriori

Model parametryczny  $\mathcal{F} = \{f_p(x): p \in \Theta\}$ .

Zgodnie z regułą Bayesa

$$\begin{aligned} f_{\text{post}}(p, x) = f_{P|X}(p, x) &= \frac{f_{X|P}(x, p) f_P(p)}{f_X(x)} = \frac{f_p(x) f_P(p)}{\int_{\Theta} f_p(x) f_P(p) dp} \\ &= \frac{f_p(x) f_{\text{prior}}(p)}{\int_{\Theta} f_p(x) f_{\text{prior}}(p) dp}, \end{aligned}$$

gdzie

$$f_p(x) = f_p(x_1) f_p(x_2) \dots f_p(x_n) = \mathcal{L}_n(x_1, \dots, x_n; p).$$

gęstość a posteriori  $\propto$  fun. wiarygodności  $\times$  gęst. a priori.

## Przykład bayesowskiego podejścia do problemu

Spotykamy znajomego, który proponuje nam zakład oparty na rzutach monetą.


Prawdopodobieństwo  $p$  wypadnięcia orła to parametr modelu.

Chcemy oszacować  $p$  przed zakładem.

W zależności od sytuacji możemy zakładać różne rozkłady a priori.


# Rozkład a priori — wariant 1

Jeśli chcemy być „obiektywni” możemy założyć rozkład jednostajny.



## Rozkład a priori — wariant 2


Wiedząc, że monety są zazwyczaj symetryczne można zakładać rozkład skupiony wokół wartości  $p = \frac{1}{2}$ .



## Rozkład a priori — wariant 3


Znając monetę (np. będąc świadkiem innych zakładów z wykorzystaniem tej samej monety), można zakładać rozkład:

**rozkład a priori, wariant 3**



## Rozkład a priori — wariant 4


Znając „przewrotność” właściciela monety można też zakładać rozkład bimodalny.



Rzucamy „próbnie” 10 razy monetą i notujemy 3 orły.

# Rozkład a posteriori — wariant 1


rozkład a posteriori, wariant 1






# Rozkład a posteriori — wariant 2

rozkład a posteriori, wariant 2




# Rozkład a posteriori — wariant 3

rozkład a posteriori, wariant 3

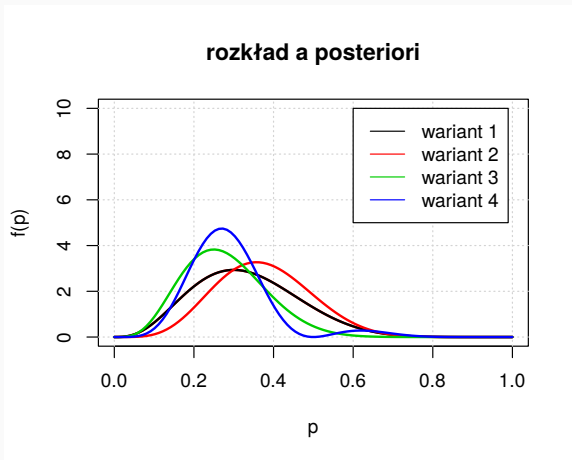


# Rozkład a posteriori — wariant 4

rozkład a posteriori, wariant 4




# Rozkład a posteriori — podsumowanie




## Rozkład a posteriori — podsumowanie (c.d.)

A gdybyśmy rzucili 20 razy uzyskując 6 orłów.




## Rozkład a posteriori — podsumowanie (c.d.)

A gdybyśmy rzucili 40 razy uzyskując 12 orłów.



## Rozkład a posteriori — podsumowanie (c.d.)

A gdybyśmy rzucili 100 razy uzyskując 30 orłów.



Model parametryczny  $\mathcal{F} = \{f_p(x): p \in \Theta\}$ .

Mając rozkład a priori parametru  $p$  (funkcja gęstości  $f_{\text{prior}}(p)$ ), parametryczny model oraz próbę  $X = (X_1, \dots, X_n)$  możemy wyznaczyć rozkład a posteriori parametru (funkcję gęstości  $f_{\text{post}}(p, x)$ ):

$$f_{\text{post}}(p, x) = \frac{\mathcal{L}_n(x; p) f_{\text{prior}}(p)}{\int_{\Theta} \mathcal{L}_n(x; p) f_{\text{prior}}(p) dp}.$$

## Definicja

Bayesowskim estymatorem  $\hat{p}$  parametru  $p$  nazywamy wartość oczekiwaną tego parametru wyliczoną za pomocą rozkładu a posteriori:

$$\hat{p} = \int_{\Theta} p f_{\text{post}}(p) dp.$$



Czasami zamiast wartości oczekiwanej wg rozkładu a posteriori, definiuje się estymator bayesowski  $\hat{p}$  jako **dominantę** (inaczej wartość modalną lub modę) rozkładu a posteriori, czyli wartość parametru  $p$ , dla której funkcja gęstości  $f_{\text{post}}$  przyjmuje wartość maksymalną.

### Fakt

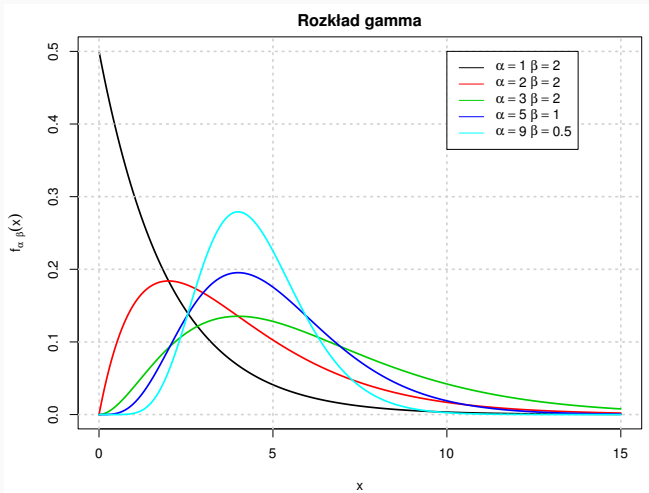
*Niezależnie od wyboru (jednej z dwóch) definicji estymatora bayesowskiego, dla dużych prób (asymptotycznie) ma on te same własności co estymator największej wiarygodności.*

# Niezwykłe użyteczne rozkłady — przypomnienie

- rozkład normalny  $N(\mu, \sigma^2)$  (nośnik  $\mathbb{R}$ ),
- rozkład gamma  $\text{Gamma}(\alpha, \beta)$  (nośnik  $[0, +\infty)$ ),
- rozkład beta  $\text{Beta}(\alpha, \beta)$  (nośnik  $[0, 1]$ ).

# Rozkład gamma — przypomnienie


$$f_X(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}, \quad \mathbb{E}X = \alpha\beta, \mathbb{V}X = \alpha\beta^2$$



# Rozkład beta — przypomnienie

$$f_X(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \alpha, \beta > 0$$

$$\mathbb{E}X = \frac{\alpha}{\alpha + \beta}, \mathbb{V}X = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$



Rozkład sprzężony dla modelu parametrycznego

$\mathcal{F} = \{f_p(x): p \in \Theta\}$ , to taki rozkład (typ rozkładu)  $X$ , że przy rozkładzie a priori typu  $X$  dostaje się rozkład a posteriori również typu  $X$  (być może z innymi parametrami). Przykłady:

model	par.	r. sprz.	par. a priori	parametry rozkł. a posteriori
Bern	$p$	Beta	$\alpha, \beta$	$\alpha + \sum_{i=1}^n x_i, \beta + n - \sum_{i=1}^n x_i$
Pois	$\lambda$	$\Gamma$	$\alpha, \beta$	$\alpha + \sum_{i=1}^n x_i, \frac{\beta}{n\beta+1}$
N	$\mu$	N	$\mu_0, \sigma_0^2$	$\frac{\mu_0\sigma_0^{-2} + \sigma^{-2} \sum_{i=1}^n x_i}{\sigma_0^{-2} + n\sigma^{-2}}, (\sigma_0^{-2} + n\sigma^{-2})^{-1}$
N	$\sigma^2$	$\Gamma^{-1}$	$\alpha, \beta$	$\alpha + n/2, \beta + \sum_{i=1}^n (x_i - \mu)^2/2$
Exp	$\lambda$	$\Gamma$	$\alpha, \beta$	$\alpha + n, \frac{\beta}{1+\beta \sum_{i=1}^n x_i}$