


ACBC-kryteria oceny reguł i reprezentowanie reguł asocjacyjnych spełniających je z użyciem szablonów

Marzena Kryszkiewicz
Politechnika Warszawska

Miary ACBC oceny jakości reguł




Miara ACBC oceny jakości reguł

Miara oceny jakości reguły $X \rightarrow Y$ jest definiowana jako miara **ACBC**, jeśli może być wyrażona przy użyciu co najwyżej:

- prawdopodobieństwa $P(X)$ poprzednika (ang. **Antecedent**) X tej reguły,
- prawdopodobieństwa $P(Y)$ jej następnika (ang. **Consequent**) Y ,
- prawdopodobieństwa $P(Z)$ jej bazy (ang. **Base**) $Z = X \cup Y$,
- Stałych (ang. **Constants**).

3




Przykłady miar ACBC oceny jakości reguł

measure	definition
$sup(X \rightarrow Y)$	$P(XY) \times D $
$conf(X \rightarrow Y)$	$P(XY) / P(X)$
$novelty(X \rightarrow Y)$	$P(XY) - P(X) \times P(Y)$
$lift(X \rightarrow Y)$	$P(XY) / (P(X) \times P(Y))$
$certainty-Factor(X \rightarrow Y)$	$\begin{cases} \frac{conf(X \rightarrow Y) - P(Y)}{1 - P(Y)} & \text{if } conf(X \rightarrow Y) > P(Y) \\ 0 & \text{if } conf(X \rightarrow Y) = P(Y) \\ \frac{P(Y) - conf(X \rightarrow Y)}{P(Y) - 0} & \text{if } conf(X \rightarrow Y) < P(Y) \end{cases}$
$cosine(X \rightarrow Y)$	$P(XY) / \sqrt{P(X) \times P(Y)}$
$Jaccard(X \rightarrow Y)$	$P(XY) / (P(X) + P(Y) - P(XY))$
$accuracy(X \rightarrow Y)$	$P(XY) + P(\bar{X}\bar{Y}) = 1 + 2P(XY) - P(X) - P(Y)$

• Wszystkie te miary oceny reguł $X \rightarrow Y$ (jak i wiele innych) można wyrazić przy użyciu co najwyżej $P(X)$, $P(Y)$, $P(XY)$ oraz stałych.

Uwaga: $P(\bar{X}\bar{Y}) = P(\bar{X}) - P(\bar{X}Y) = (1 - P(X)) - (P(Y) - P(XY))$.

4




Relatywne wsparcie reguły asocjacyjnej

- Relatywne wsparcie reguły asocjacyjnej $X \rightarrow Y$ jest definiowane jako prawdopodobieństwo współwystąpienia X i Y :

$$rSup(X \rightarrow Y) = P(XY) = sup(XY) / |D|.$$

- **Własność.** Relatywne wsparcie zależy od prawdopodobieństwa wystąpienia bazy reguły, ale nie zależy od prawdopodobieństwa wystąpienia jej poprzednika, ani następnika.

5



Zaufanie reguły asocjacyjnej

- Zaufanie reguły asocjacyjnej $X \rightarrow Y$ jest definiowane jako warunkowe prawdopodobieństwo wystąpienia Y pod warunkiem wystąpienia X :

$$conf(X \rightarrow Y) = P(XY) / P(X).$$

- **Własność.** Zaufanie zależy od prawdopodobieństw wystąpienia poprzednika i bazy reguły, ale nie zależy od prawdopodobieństwa wystąpienia jej następnika.

6

(Nie)zależność zdarzeń

- X i Y są **niezależne**, jeśli:
 $P(XY) = P(X) \times P(Y)$.
- Wpp. są zwane **zależnymi**.
- **Naturalna interpretacja:**
 - Jeżeli $P(XY) > P(X) \times P(Y)$, to X i Y są zależne pozytywnie.
 - Jeżeli $P(XY) = P(X) \times P(Y)$, to X i Y są niezależne.
 - Jeżeli $P(XY) < P(X) \times P(Y)$, to X i Y są zależne negatywnie.
- **Własność.** Fakt, że $P(XY) \neq P(X) \times P(Y)$ nie określa stopnia, w jakim X i Y są zależne.

Zaufanie a (nie)zależność zdarzeń...

Tld	X	Y
1		x
2		x
3		x
4		x
5		x
6		x
7		x
8		x
9	x	x
10	x	

- $P(X) = \frac{2}{10}, P(Y) = \frac{9}{10} \Rightarrow P(X) \times P(Y) = 0.18$.
- $P(XY) = \frac{1}{10} = 0.1 < 0.18 = P(X) \times P(Y)$, czyli **X i Y są zależne negatywnie.**
- $\text{conf}(X \rightarrow Y) = P(XY) / P(X) = \frac{1}{2}$.
- $P(X) = \frac{2}{10}, P(\bar{Y}) = \frac{1}{10} \Rightarrow P(X) \times P(\bar{Y}) = 0.02$.
- $P(X\bar{Y}) = \frac{1}{10} = 0.1 > 0.02 = P(X) \times P(\bar{Y})$, czyli **X i \bar{Y} są zależne pozytywnie.**
- $\text{conf}(X \rightarrow \bar{Y}) = P(X\bar{Y}) / P(X) = \frac{1}{2}$.

Zaufanie a (nie)zależność zdarzeń

Tld	X	Y
1		x
2		x
3		x
4		x
5		x
6		x
7		x
8	x	x
9	x	x
10	x	

- $P(X) = \frac{3}{10}, P(Y) = \frac{9}{10} \Rightarrow P(X) \times P(Y) = 0.27$.
- $P(XY) = \frac{2}{10} = 0.2 < 0.27 = P(X) \times P(Y)$, czyli **X i Y są zależne negatywnie.**
- $\text{conf}(X \rightarrow Y) = P(XY) / P(X) = \frac{2}{3}$.
- $P(X) = \frac{3}{10}, P(\bar{Y}) = \frac{1}{10} \Rightarrow P(X) \times P(\bar{Y}) = 0.03$.
- $P(X\bar{Y}) = \frac{1}{10} = 0.1 > 0.03 = P(X) \times P(\bar{Y})$, czyli **X i \bar{Y} są zależne pozytywnie.**
- $\text{conf}(X \rightarrow \bar{Y}) = P(X\bar{Y}) / P(X) = \frac{1}{3}$.

Współczynnik podniesienia (lift)

- **Współczynnik podniesienia** (ang. *lift*) dla reguły asocjacyjnej $X \rightarrow Y$ jest definiowany jako stosunek prawdopodobieństwa warunkowego wystąpienia Y pod warunkiem wystąpienia X do prawdopodobieństwa wystąpienia Y :

$$\text{lift}(X \rightarrow Y) = \frac{\text{conf}(X \rightarrow Y)}{P(Y)} = \frac{P(XY)}{P(X) \times P(Y)}$$

- **Własność.**

(Nie)zależność	Warunek na (nie)zależność	Równoważny warunek	Równoważny warunek
Y i X są zależne pozytywnie	$P(XY) > P(X) \times P(Y)$	$\text{lift}(X \rightarrow Y) > 1$	$\text{lift}(Y \rightarrow X) > 1$
Y i X są niezależne	$P(XY) = P(X) \times P(Y)$	$\text{lift}(X \rightarrow Y) = 1$	$\text{lift}(Y \rightarrow X) = 1$
Y i X są zależne negatywnie	$P(XY) < P(X) \times P(Y)$	$\text{lift}(X \rightarrow Y) < 1$	$\text{lift}(Y \rightarrow X) < 1$

- **Własność.** $\text{lift}(X \rightarrow Y) = \text{lift}(Y \rightarrow X)$.

Lift a (nie)zależność zdarzeń

Tld	X	Y	Z	V
1	x	x		
2	x	x		
3	x	x		
4	x	x		
5	x	x		
6	x	x		
7	x	x		
8	x	x		
9	x	x		
10		x	x	

- $P(X) = \frac{9}{10}, P(Y) = \frac{9}{10} \Rightarrow P(X) \times P(Y) = 0.81$.
- $P(XY) = \frac{9}{10} = 0.9 > 0.81 = P(X) \times P(Y)$, czyli **X i Y są zależne pozytywnie.**
- $\text{lift}(X \rightarrow Y) = \frac{P(XY)}{P(X) \times P(Y)} = \frac{0.9}{0.9 \times 0.9} = \frac{10}{9} = 1\frac{1}{9}$.
- $P(Z) = \frac{1}{10}, P(V) = \frac{1}{10} \Rightarrow P(Z) \times P(V) = 0.01$.
- $P(ZV) = \frac{1}{10} = 0.1 > 0.01 = P(Z) \times P(V)$, czyli **Z i V są zależne pozytywnie.**
- $\text{lift}(Z \rightarrow V) = \frac{P(ZV)}{P(Z) \times P(V)} = \frac{0.1}{0.1 \times 0.1} = \frac{10}{1} = 10$.

Współczynnik pewności (cf)...

- **Współczynnik pewności** (ang. *certainty factor*, *cf*) dla reguły asocjacyjnej $X \rightarrow Y$ jest definiowany jako stopień, w jakim prawdopodobieństwo wystąpienia Y może ulec zmianie pod warunkiem wystąpienia X :

$$cf(X \rightarrow Y) = \begin{cases} \frac{\text{conf}(X \rightarrow Y) - P(Y)}{1 - P(Y)} & \text{if } \text{conf}(X \rightarrow Y) > P(Y), \\ 0 & \text{if } \text{conf}(X \rightarrow Y) = P(Y), \\ -\frac{P(Y) - \text{conf}(X \rightarrow Y)}{P(Y) - 0} & \text{if } \text{conf}(X \rightarrow Y) < P(Y). \end{cases}$$

0 $P(Y)$ $\text{conf}(X \rightarrow Y)$ 1

0 $\text{conf}(X \rightarrow Y)$ $P(Y)$ 1

Współczynnik pewności (cf)

$$cf(X \rightarrow Y) = \begin{cases} \frac{conf(X \rightarrow Y) - P(Y)}{1 - P(Y)} & \text{if } conf(X \rightarrow Y) > P(Y), \\ 0 & \text{if } conf(X \rightarrow Y) = P(Y), \\ -\frac{P(Y) - conf(X \rightarrow Y)}{P(Y) - 0} & \text{if } conf(X \rightarrow Y) < P(Y). \end{cases}$$

• Własność:

$$cf(X \rightarrow Y) = \begin{cases} \frac{P(XY) - P(X) \times P(Y)}{P(X) - P(X) \times P(Y)} & \text{if } P(XY) > P(X) \times P(Y), \\ 0 & \text{if } P(XY) = P(X) \times P(Y), \\ -\frac{P(X) \times P(Y) - P(XY)}{P(X) \times P(Y) - 0} & \text{if } P(XY) < P(X) \times P(Y). \end{cases}$$

asymetryczne dla X i Y

symetryczne dla X i Y

Wartości ekstremalne miar regułowych

miara	maks.	min.
$P(XY)$	1	0
$conf(X \rightarrow Y)$	1	0
$lift(X \rightarrow Y)$	∞	0
$cf(X \rightarrow Y)$	1	-1

dla zależności pozytywnej pomiędzy X i Y

dla zależności negatywnej pomiędzy X i Y

Wartości ekstremalne $P(XY)$ dla zadanych $P(X)$ & $P(Y)$...

• Własność.

a) $\max_{P(XY)} P(XY) = \min\{P(X), P(Y)\}$

b) $\min_{P(XY)} P(XY) = \begin{cases} 0 & \text{if } P(X) + P(Y) \leq 1 \\ P(X) + P(Y) - 1 & \text{if } P(X) + P(Y) > 1 \end{cases}$

$= \max\{0, P(X) + P(Y) - 1\}$

X	Y
x	x
x	x
x	x
x	

X	Y
x	
x	
x	
x	
	x
	x
	x

X	Y
x	
x	
x	
x	
x	x
x	x
x	x

Wartości ekstremalne $P(XY)$ dla zadanych $P(X)$ & $P(Y)$

• Własność.

zamiast 1

zamiast 0

miara	maks. dla ustalonych wartości $P(X)$ i $P(Y)$	min. dla ustalonych wartości $P(X)$ i $P(Y)$
$P(XY)$	$\min\{P(X), P(Y)\}$	$\max\{0, P(X) + P(Y) - 1\}$
$conf(X \rightarrow Y)$	$\frac{\min\{P(X), P(Y)\}}{P(X)}$	$\frac{\max\{0, P(X) + P(Y) - 1\}}{P(X)}$
$lift(X \rightarrow Y)$	$\frac{\min\{P(X), P(Y)\}}{P(X) \times P(Y)}$	$\frac{\max\{0, P(X) + P(Y) - 1\}}{P(X) \times P(Y)}$
$cf(X \rightarrow Y)$	$\frac{\min\{P(X), P(Y)\} - P(X) \times P(Y)}{P(X) - P(X) \times P(Y)}$ dla zależności pozytywnej pomiędzy X i Y	$-\frac{P(X) \times P(Y) - \max\{0, P(X) + P(Y) - 1\}}{P(X) \times P(Y) - 0}$ dla zależności negatywnej pomiędzy X i Y

Współczynnik zależności (df)

• Współczynnik zależności (ang. *dependence factor*, *df*) dla reguły asocjacyjnej $X \rightarrow Y$ jest definiowany jako stopień, w jakim prawdopodobieństwo wystąpienia Y może ulec zmianie pod warunkiem wystąpienia X i Y z prawdopodobieństwem odpowiednio $P(X)$ i $P(Y)$:

zamiast 1

$$df(X \rightarrow Y) = \begin{cases} \frac{conf(X \rightarrow Y) - P(Y)}{\max_{P(XY)} P(XY) - P(Y)} & \text{if } conf(X \rightarrow Y) > P(Y), \\ 0 & \text{if } conf(X \rightarrow Y) = P(Y), \\ -\frac{P(Y) - conf(X \rightarrow Y)}{P(Y) - \min_{P(XY)} P(XY)} & \text{if } conf(X \rightarrow Y) < P(Y). \end{cases}$$

zamiast 0

Ekstremalne wartości współczynnika zależności df

• Własność.

miara	maks. (dla pozytywnej zależności pomiędzy X i Y)	min. (dla negatywnej zależności pomiędzy X i Y)
$df(X \rightarrow Y)$ przy ustalonych wartościach $P(X)$ i $P(Y)$	1	-1

zamiast 1

$$df(X \rightarrow Y) = \begin{cases} \frac{conf(X \rightarrow Y) - P(Y)}{\max_{P(XY)} P(XY) - P(Y)} & \text{if } conf(X \rightarrow Y) > P(Y), \\ 0 & \text{if } conf(X \rightarrow Y) = P(Y), \\ -\frac{P(Y) - \min_{P(XY)} P(XY)}{P(Y) - \min_{P(XY)} P(XY)} & \text{if } conf(X \rightarrow Y) < P(Y). \end{cases}$$

zamiast 0

Współczynnik zależności df w terminach prawdopodobieństw...

zamiast 1

$$df(X \rightarrow Y) = \begin{cases} \frac{P(XY) - P(X) \times P(Y)}{\max_{P(XY) | P(X), P(Y)} - P(X) \times P(Y)} & \text{if } P(XY) > P(X) \times P(Y), \\ 0 & \text{if } P(XY) = P(X) \times P(Y), \\ -\frac{P(X) \times P(Y) - P(XY)}{P(X) \times P(Y) - \min_{P(XY) | P(X), P(Y)}} & \text{if } P(XY) < P(X) \times P(Y). \end{cases}$$

zamiast 0

19

Współczynnik zależności df w terminach prawdopodobieństw

zamiast 1

$$df(X \rightarrow Y) = \begin{cases} \frac{P(XY) - P(X) \times P(Y)}{\max_{P(XY) | P(X), P(Y)} - P(X) \times P(Y)} & \text{if } P(XY) > P(X) \times P(Y), \\ 0 & \text{if } P(XY) = P(X) \times P(Y), \\ -\frac{P(X) \times P(Y) - P(XY)}{P(X) \times P(Y) - \min_{P(XY) | P(X), P(Y)}} & \text{if } P(XY) < P(X) \times P(Y). \end{cases}$$

zamiast 0

• Własność. $df(X \rightarrow Y) = df(Y \rightarrow X)$.

20

Współczynnik zależności df a współczynnik pewności cf

• Własność.

- $df(X \rightarrow Y) = cf(X \rightarrow Y) = 0$, jeśli $P(XY) = P(X) \times P(Y)$.
- $|df(X \rightarrow Y)| \geq |cf(X \rightarrow Y)|$, jeśli $P(XY) \neq P(X) \times P(Y)$.
- If $P(XY) > P(X) \times P(Y)$, then $df(X \rightarrow Y) = \max\{cf(X \rightarrow Y), cf(Y \rightarrow X)\}$.
- If $P(XY) < P(X) \times P(Y)$, then:
 - $df(X \rightarrow Y) = cf(X \rightarrow Y)$, jeśli $P(X) + P(Y) \leq 1$.
 - $|df(X \rightarrow Y)| > |cf(X \rightarrow Y)|$, jeśli $P(X) + P(Y) > 1$.

21

Współczynnik zależności: $P(X) + P(Y) \leq 1$

• Tabela. Porównanie wartości $lift(X \rightarrow Y)$, $cf(X \rightarrow Y)$ oraz $df(X \rightarrow Y)$, gdy $P(X) + P(Y) \leq 1$

P(X)	P(Y)	P(XY)	P(X)×P(Y)	lift(X→Y)	cf(X→Y)	cf(Y→X)	df(X→Y)=df(Y→X)
0.60	0.30	0.30	0.18	1.67	0.29	1.00	1.00
0.60	0.30	0.25	0.18	1.39	0.17	0.58	0.58
0.60	0.30	0.20	0.18	1.11	0.05	0.17	0.17
0.60	0.30	0.18	0.18	1.00	0.00	0.00	0.00
0.60	0.30	0.15	0.18	0.83	-0.17	-0.17	-0.17
0.60	0.30	0.10	0.18	0.56	-0.44	-0.44	-0.44
0.60	0.30	0.00	0.18	0.00	-1.00	-1.00	-1.00

22

Współczynnik zależności: $P(X) + P(Y) > 1$

• Tabela. Porównanie wartości $lift(X \rightarrow Y)$, $cf(X \rightarrow Y)$ oraz $df(X \rightarrow Y)$, gdy $P(X) + P(Y) > 1$

P(X)	P(Y)	P(XY)	P(X)×P(Y)	lift(X→Y)	cf(X→Y)	cf(Y→X)	df(X→Y)=df(Y→X)
0.80	0.60	0.60	0.48	1.25	0.38	1.00	1.00
0.80	0.60	0.55	0.48	1.15	0.22	0.58	0.58
0.80	0.60	0.50	0.48	1.04	0.06	0.17	0.17
0.80	0.60	0.48	0.48	1.00	0.00	0.00	0.00
0.80	0.60	0.45	0.48	0.94	-0.06	-0.06	-0.37
0.80	0.60	0.40	0.48	0.83	-0.17	-0.17	-1.00

23


Współczynnik zależności a miara lift

zamiast ∞

$$df(X \rightarrow Y) = \begin{cases} \frac{lift(X \rightarrow Y) - 1}{\max_{lift(X \rightarrow Y) | P(X), P(Y)} - 1} & \text{if } lift(X \rightarrow Y) > 1, \\ 0 & \text{if } lift(X \rightarrow Y) = 1, \\ -\frac{1 - lift(X \rightarrow Y)}{1 - \min_{lift(X \rightarrow Y) | P(X), P(Y)}} & \text{if } lift(X \rightarrow Y) < 1. \end{cases}$$

zamiast 0

24

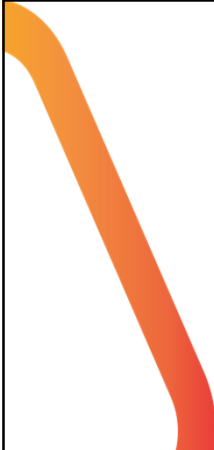


Zależność pomiędzy X i Y , a zależności pomiędzy \bar{X} i Y , X i \bar{Y} , \bar{X} i \bar{Y}


- **Twierdzenie.**

$$df(X \rightarrow Y) = df(\bar{X} \rightarrow \bar{Y}) = -df(X \rightarrow \bar{Y}) = -df(\bar{X} \rightarrow Y).$$

25



Reprezentacja szablonowa reguł spełniających różnorodne kryteria oparte na miarach ACBC



Reguły spełniające różnorodne kryteria oparte na miarach ACBC


Niech:

- M będzie zbiorem $\{\mu_1, \dots, \mu_n\}$ miar ACBC
- oraz
- $E = \{\varepsilon_1, \dots, \varepsilon_n\}$ będzie zbiorem odpowiadających im wartości progowych.

Reguła $X \rightarrow Y$ jest definiowana jako **silna ze względu na miary M i wartości progowe E** (krótko: jako **(M, E) -reguła**), jeżeli:

$$\forall \mu_i \in M (\mu_i(X \rightarrow Y) > \varepsilon_i).$$

27



Własność miary ACBC


Własność. Niech:

- $X \rightarrow Y$ i $Z \rightarrow V$ będą regułami, dla których zachodzi:
 $P(X) = P(Z), P(Y) = P(V), P(XY) = P(ZV)$
- oraz
- μ będzie miarą ACBC.

Wtedy:

$$\mu(X \rightarrow Y) = \mu(Z \rightarrow V).$$


28



Reprezentowanie reguł spełniających wiele kryteriów opartych na miarach ACBC

- Liczba reguł spełniających wiele kryteriów opartych na miarach ACBC może być olbrzymia.
- Szablony regułowe mogą być użyte do reprezentowania reguł spełniających różnorodne kryteria oparte na miarach ACBC.
- Szablony regułowe są tworzone z użyciem dwóch typów zbiorów:
 - **zbiorów zamkniętych** oraz
 - **generatorów kluczowych**.

29



Zbiory zamknięte - przypomnienie

- **Domknięciem zbioru X** o niezerowym wsparciu (czyli zawartym w co najmniej jednej transakcji) jest przecięcie wszystkich transakcji zawierających X . Wpp. **domknięciem zbioru X** jest uniwersum (zbiór wszystkich pozycji).
- **Własność.** Domknięcie zbioru X jest największym nadzbiorem zbioru X , występującym w tych samych transakcjach co zbiór X (czyli występującym w tej samej liczbie transakcji co zbiór X).
- **Zbiór X** jest definiowany jako **zbiór zamknięty**, jeśli X jest swoim domknięciem; czyli, jeśli:

$$\forall Y \supset X, t(Y) \subset t(X)$$
 (lub równoważnie, $\forall Y \supset X, \sup(Y) < \sup(X)$).

30

Istotna własność zbiorów zamkniętych

Niech X będzie zbiorem, a Y zbiorem zamkniętym, stanowiącym domknięcie zbioru X . Wtedy:

- X i Y występują w tych samych transakcjach.
- X i Y mają to samo wsparcie.
- Y jest domknięciem każdego zbioru U , spełniającego warunek: $X \subseteq U \subseteq Y$.
- Każdy zbiór U , spełniający warunek: $X \subseteq U \subseteq Y$, ma to samo wsparcie co zbiór Y .

31

Generatory kluczowe - przypomnienie

- Zbiór Y jest definiowany jako *generator* zbioru X , jeśli Y jest minimalnym podzbiorem zbioru X , który występuje w tych samych transakcjach co zbiór X .
- Własność.** Każdy zbiór ma co najmniej jeden generator.
- Zbiór X jest definiowany jako **generator kluczowy**, jeśli X jest swoim (jedynym) generatorem, czyli, jeżeli:

$$\forall Y \subset X, t(Y) \supset t(X)$$
 (lub równoważnie, $\forall Y \subset X, \text{sup}(Y) > \text{sup}(X)$).

32

Przykład: Generatory kluczowe i zbiory zamknięte

Tabela 1. Przykładowy zbiór D z transakcjami

Transaction Id	Transaction
#1	{abcde}
#2	{abcdef}
#3	{abcdehi}
#4	{abe}
#5	{bcdehi}

Tabela 2. Częste zbiory zamknięte i częste generatory kluczowe odkryte w zbiorze D transakcji

Częste zbiory zamknięte	Częste generatory kluczowe	Wsparcie relatywne
{be}	\emptyset	5/5
{abe}	{a}	4/5
{bcde}	{c}, {d}	4/5
{abcde}	{ac}, {ad}	3/5
{bcdehi}	{h}, {i}	2/5
{abcdei}	{i}	1/5
{abcdehi}	{ah}, {ai}	1/5

33

Przykład: Wnioskowanie z użyciem generatorów kluczowych i zbiorów zamkniętych

Transaction Id	Transaction
#1	{abcde}
#2	{abcdef}
#3	{abcdehi}
#4	{abe}
#5	{bcdehi}

- $\{h\}$ jest generatorem kluczowym.
- $\{bcdehi\}$ jest zbiorem zamkniętym, który jest domknięciem zbioru $\{h\}$.
- Każdy zbiór U , spełniający warunek: $\{h\} \subseteq U \subseteq \{bcdehi\}$, ma takie samo wsparcie co zbiór $\{h\}$ i zbiór $\{bcdehi\}$ (tutaj: 2). Liczba takich zbiorów U wynosi 32.

34

Szablony regułowe

Para dwóch reguł ($X \rightarrow Y, Z \rightarrow V$) jest definiowana jako szablon regułowy (ang. *rule template*), jeśli:

- X i Y są generatorami kluczowymi oraz $X \cap Y = \emptyset$,
- Z i V są zbiorami zamkniętymi,
- Z jest domknięciem zbioru X , a V jest domknięciem zbioru Y .

$X \rightarrow Y$ jest zwana *regułą dolną* szablonu ($X \rightarrow Y, Z \rightarrow V$).
 $Z \rightarrow V$ jest zwana *regułą górną* szablonu ($X \rightarrow Y, Z \rightarrow V$).

35

Szablony regułowe i ich własności

Reguła $U \rightarrow W$ jest definiowana jako **pokryta przez szablon regułowy** ($X \rightarrow Y, Z \rightarrow V$), jeśli $X \subseteq U \subseteq Z$ i $Y \subseteq W \subseteq V$.

Twierdzenie. Niech ($X \rightarrow Y, Z \rightarrow V$) będzie szablonem regułowym pokrywającym regułę $U \rightarrow W$. Wtedy:

- $P(X) = P(U) = P(Z)$.
- $P(Y) = P(W) = P(V)$.
- $P(XY) = P(UW) = P(ZV)$.
- Dla każdej ewaluacyjnej miary ACBC μ :

$$\mu(X \rightarrow Y) = \mu(U \rightarrow W) = \mu(Z \rightarrow V).$$

36

Moc pokrycia szablonu regułowego

Twierdzenie. Szablon regułowy $(X \rightarrow Y, Z \rightarrow V)$ pokrywa $2^m \times 2^n \times 3^k$ unikatowych reguł asocjacyjnych, gdzie:

- $\Delta_{\text{Common}} = (Z \cap V) \setminus (X \cup Y)$,
- $\Delta_{\text{antecedent}} = Z \setminus (X \cup V)$;
- $\Delta_{\text{consequent}} = V \setminus (Y \cup Z)$;
- $k = |\Delta_{\text{Common}}|$; $m = |\Delta_{\text{antecedent}}|$; $n = |\Delta_{\text{consequent}}|$.

Przykład. Niech R oznacza szablon regułowy:
 $(\{a\} \rightarrow \{ij\}, \{abcdef\} \rightarrow \{efghij\})$.
 Wtedy: $\Delta_{\text{Common}} = \{ef\}$, $\Delta_{\text{antecedent}} = \{bcd\}$, $\Delta_{\text{consequent}} = \{gh\}$.
 Zatem, szablon regułowy R pokrywa $2^1 |\{bcd\}| \times 2^1 |\{gh\}| \times 3^1 |\{ef\}| = 2^3 \times 2^2 \times 3^2 = 288$ reguł asocjacyjnych.

(M, E) -szablony regułowe

- Niech M będzie zbiorem miar regułowych ACBC. Szablon regułowy $(X \rightarrow Y, Z \rightarrow V)$ jest nazywany **(M, E) -szablonem regułowym**, jeśli:

$$\forall \mu_i \in M, \varepsilon_i \in E (\mu_i(X \rightarrow Y) > \varepsilon_i)$$

(lub alternatywnie, $\forall \mu_i \in M, \varepsilon_i \in E (\mu_i(Z \rightarrow V) > \varepsilon_i)$).

(M, E) -szablony regułowe jako reprezentacja (M, E) -silnych reguł asocjacyjnych

Twierdzenie. Niech M będzie zbiorem miar regułowych ACBC, a $U \rightarrow W$ będzie regułą asocjacyjną.

- Jeśli istnieje (M, E) -szablon regułowy $(X \rightarrow Y, Z \rightarrow V)$ pokrywający $U \rightarrow W$, to $U \rightarrow W$ jest (M, E) -regułą asocjacyjną oraz

$$\forall \mu_i \in M (\mu_i(U \rightarrow W) = \mu_i(X \rightarrow Y) = \mu_i(Z \rightarrow V)).$$

- Wpp., $U \rightarrow W$ nie jest (M, E) -regułą asocjacyjną.

Przykład: (M, E) -szablony regułowe jako reprezentacja (M, E) -reguł asocjacyjnych

Zbiór danych D

Tid	Transaction
#1	{abcde}
#2	{abcdef}
#3	{abcdehi}
#4	{abe}
#5	{bcdehi}

(M, E) -szablon regułowy	rSup	novelty	lift	certaintyFactor
$(\{h\} \rightarrow \{i\}, \{bcdehi\} \rightarrow \{bcdehi\})$	2/5	0.24	2.5	1
$(\{h\} \rightarrow \{ai\}, \{bcdehi\} \rightarrow \{bcdehi\})$	1/5	0.12	2.5	0.375
$(\{i\} \rightarrow \{h\}, \{bcdehi\} \rightarrow \{bcdehi\})$	2/5	0.24	2.5	1
$(\{i\} \rightarrow \{ah\}, \{bcdehi\} \rightarrow \{bcdehi\})$	1/5	0.12	2.5	0.375
$(\{ah\} \rightarrow \{i\}, \{bcdehi\} \rightarrow \{bcdehi\})$	1/5	0.12	2.5	1
$(\{ai\} \rightarrow \{h\}, \{bcdehi\} \rightarrow \{bcdehi\})$	1/5	0.12	2.5	1

- Niech zbiór miar regułowych ACBC $M = \{rSup, novelty, lift, certaintyFactor\}$ oraz
- zbiór odpowiadających im wartości progowych $E = \{0, 0.1, 2.0, 0.3\}$.


Wtedy jest 6 (M, E) -szablonów regułowych, które pokrywają 486 (M, E) -reguł asocjacyjnych.

Literatura

- Marzena Kryszkiewicz: Concise Representations of Frequent Patterns and Association Rules, Warsaw: Publishing House of Warsaw University of Technology (2002)
- Marzena Kryszkiewicz: A Lossless Representation for Association Rules Satisfying Multiple Evaluation Criteria. Proceedings of ACIIDS 2016, LNCS, vol. 9622, 2016, Springer
- Marzena Kryszkiewicz: ACBC-Adequate Association and Decision Rules Versus Key Generators and Rough Sets Approximations. *Fundam. Inform.* 148(1-2): 65-85 (2016)
- Marzena Kryszkiewicz: Representative Rule Templates for Association Rules Satisfying Multiple Canonical Evaluation Criteria. *ACIIDS (1) 2018*: 550-561

Ćwiczenia...

- Pokaż, że współczynnik zależności df (ang. dependence factor) jest miarą ACBC.
- Niech zbiór ACBC-miar regułowych:
 - $M = \{rSup, conf, dependenceFactor\}$ oraz zbiór odpowiadających im wartości progowych:
 - $E = \{2/5, 0.45, 1\}$.
 Wyznacz (M, E) -szablony regułowe na podstawie zbioru danych ze slajdu 33.



PLATFORMA EDUKACYJNA

Ćwiczenia

3. Wyznacz liczbę reguł asocjacyjnych pokrytych przez szablon regułowy $(\{ah\} \rightarrow \{i\}, \{abcdehi\} \rightarrow \{bcdehi\})$.
4. Wyznacz zbiór reguł asocjacyjnych pokrytych przez szablon regułowy $(\{ah\} \rightarrow \{i\}, \{abcdehi\} \rightarrow \{bcdehi\})$.
5. Na podstawie zbioru szablonów reguł zamieszczonych na slajdzie 40 wyznacz te szablony, które pokrywają regułę $\{bch\} \rightarrow \{aei\}$ oraz na tej podstawie wyznacz wartości miar *rSup*, *novelty*, *lift* i *certaintyFactor* dla tej reguły.

43