



Data Science

Metody Sztucznej Inteligencji

Paweł Wawrzyński

Przeszukiwanie
Algorytmy ewolucyjne

Dzisiaj

- Zagadnienie przeszukiwania (optymalizacji)
- Podejścia do przeszukiwania
- Idea algorytmów ewolucyjnych
- Algorytm (1+1)
 - mutacja
- Algorytm zrównoleglony (1+1)
- Algorytm ($\mu+\lambda$)
 - krzyżowanie
- CMA-ES

Przeszukiwanie - optymalizacja

- W przestrzeni X
- istnieje funkcja $f : X \rightarrow \mathbb{R}$
jest to funkcja celu / kryterium jakości
- Chodzi o znalezienie x maksymalizującego f
- Przykłady:
 - najlepsze parametry dla procesu technicznego lub ekonomicznego
 - najlepsza struktura procesu j.w.
 - najlepsza struktura sieci telekomunikacyjnej

Podejścia do optymalizacji

- Przegląd wszystkich możliwości
- Metody przeglądowe z eliminacją
 - np. alg. podziału i oszacowań
- Metody analityczne
 - np. alg. gradientów sprzężonych
- Metody losowe
 - alg. ewolucyjne, genetyczne
 - symulowane wyżarzanie

Idea algorytmów ewolucyjnych

- Osobnik
- Populacja
- Reprodukacja, potomstwo
 - mutacja
 - krzyżowanie
- f – funkcja przystosowania

Ogólny algorytm ewolucyjny

1. Wygeneruj populację początkową P
2. Reprodukuj z P zbiór osobników R
3. Wybierz z $P \cup R$ nową populację P
4. Jeśli nie jest spełniony warunek stopu, wróć do punktu 2, w przeciwnym razie zwróć najlepszego osobnika z P


Algorytm (1+1)

Parametry: n - wymiar X , naturalne m oraz początkowe $\sigma > 0$

1. Wygeneruj pierwszego osobnika $x \in X$
2. Wygeneruj potomka $y = x + \sigma N(0, I)$
3. Wybierz $x = f(x) > f(y) ? x : y$
4. Zaktualizuj φ jako proporcję wybranych y -ków w ciągu ostatnich m iteracji.
5. Co m -ty krok dokonaj przypisania:
$$\sigma = \begin{cases} c_1 \sigma & \text{dla } \varphi < 1/5 \\ c_2 \sigma & \text{dla } \varphi > 1/5 \\ \sigma & \text{dla } \varphi = 1/5 \end{cases}$$
6. Jeśli $\sigma < \sigma_{\min}$, zakończ przyjmując x jako wynik;
w przeciwnym razie wróć do Punktu 2.
- Algorytm działa nieźle dla $m = 10$, $c_1 = 0,82$ oraz $c_2 = 1,2$

Mutacja w algorytmie (1+1)


- Zmutowany osobnik y powstaje przez losowe zaburzenie x .
- Dlaczego 1/5?



Zrównoleglony (1+1)

1. Wybierz $x_r \in X$; będzie to wartość dostępna w sposób wyłączny dla wszystkich wątków algorytmu
2. W zbiorze niezależnych wątków realizuj tą samą procedurę:
Powtarzaj
 - a) x = wynik działania algorytmu (1+1)
 - b) jeżeli $f(x) > f(x_r)$, przypisz $x_r = x$dopóki nie wystąpił warunek stopu
3. Zwróć x_r

Skalowanie argumentów funkcji przystosowania



- Algorytm: (1+1)
- Przykład, reakcja chemiczna
 - temperatura $[20, 80]$
 - stężenie katalizatora $[10^{-5}, 10^{-4}]$
 - tempo optymalizacji temp. takie jak stężenia
- Remedium: skalowanie wymiarów, np.
 - przeszukiwanie przestrzeni: $[20, 80] \times [10, 100]$
 - której drugi wymiar to stężenie $\times 10^6$

Algorytm $(\mu+\lambda)$

Parametry: n - wymiar X , naturalne μ oraz λ ($\mu < \lambda$)

1. Wygeneruj P - populację μ osobników postaci
 $\langle x_1, \dots, x_n, \sigma_1, \dots, \sigma_n \rangle$
2. Wylosuj z P λ -elementową tymczasową populację T
3. Reprodukuj z T λ -elementową populację potomną R stosując krzyżowanie i mutację.
4. Utwórz P jako μ osobników wybranych z $P \cup R$.
5. Jeśli jest spełniony warunek stopu, zwróć wynik jako najlepszy element P ;
w przeciwnym razie wróć do punktu 2.

Algorytm $(\mu+\lambda)$ - krok 2.

- Wielokrotne losowanie ze zwracaniem

Parametry: n - wymiar X , naturalne μ oraz λ ($\mu < \lambda$)

1. Wygeneruj P - populację μ osobników postaci
 $\langle x_1, \dots, x_n, \sigma_1, \dots, \sigma_n \rangle$
2. Wylosuj z P λ -elementową tymczasową populację T
3. Reprodukuj z T λ -elementową populację potomną R stosując krzyżowanie i mutację.
4. Utwórz P jako μ osobników wybranych z $P \cup R$.
5. Jeśli jest spełniony warunek stopu, zwróć wynik jako najlepszy element P ;
w przeciwnym razie wróć do punktu 2.

Algorytm $(\mu+\lambda)$ - krzyżowanie

- Uśrednianie:

$$\langle \bar{x}, \bar{\sigma} \rangle = \langle (x^f + x^m)/2, (\sigma^f + \sigma^m)/2 \rangle$$

- Interpolacja

$$\langle \bar{x}, \bar{\sigma} \rangle = \langle a x^f + (1-a) x^m, a \sigma^f + (1-a) \sigma^m \rangle$$

dla

$$a \sim U(0,1)$$

Parametry: n - wymiar X , naturalne μ oraz λ ($\mu < \lambda$)

1. Wygeneruj P - populację μ osobników postaci $\langle x_1, \dots, x_n, \sigma_1, \dots, \sigma_n \rangle$
2. Wylosuj z P λ -elementową tymczasową populację T
3. Reprodukuj z T λ -elementową populację potomną R stosując krzyżowanie i mutację.
4. Utwórz P jako μ osobników wybranych z $P \cup R$.
5. Jeśli jest spełniony warunek stopu, zwróć wynik jako najlepszy element P ;
w przeciwnym razie wróć do punktu 2.

Algorytm $(\mu+\lambda)$ - mutacja

- Natężenie rozmywania

$$\sigma_i^R = \bar{\sigma}_i \exp(\tau N(0,1) + \tau' N_i(0,1))$$

$$\tau = \frac{1}{\sqrt{2d}}, \quad \tau' = \frac{1}{\sqrt{2}\sqrt{d}}, \quad d = \dim(x)$$

- Rozwiązanie

$$x_i^R = \bar{x}_i + \sigma_i^R N_i(0,1)$$

Parametry: n - wymiar X , naturalne μ oraz λ ($\mu < \lambda$)

1. Wygeneruj P - populację μ osobników postaci $\langle x_1, \dots, x_n, \sigma_1, \dots, \sigma_n \rangle$
2. Wylosuj z P λ -elementową tymczasową populację T
3. Reprodukuj z T λ -elementową populację potomną R stosując krzyżowanie i mutację.
4. Utwórz P jako μ osobników wybranych z $P \cup R$.
5. Jeśli jest spełniony warunek stopu, zwróć wynik jako najlepszy element P ;
w przeciwnym razie wróć do punktu 2.

Algorytm $(\mu+\lambda)$ - wybór

- μ najlepszych.
- Metoda koła ruletki: osobniki są losowane z prawdopodobieństwem proporcjonalnym do


$$g(f(x)), \quad \text{np. } g(y) = e^y$$

- Selekcja rankingowa
p-stwo wyboru x
proporcjonalne do
 $\mu + \lambda + 1 - \text{pozycja}(x)$

Parametry: n - wymiar X , naturalne μ oraz λ ($\mu < \lambda$)

1. Wygeneruj P - populację μ osobników postaci
 $\langle x_1, \dots, x_n, \sigma_1, \dots, \sigma_n \rangle$
2. Wylosuj z P λ -elementową tymczasową populację T
3. Reprodukuj z T λ -elementową populację potomną R stosując krzyżowanie i mutację.
4. Utwórz P jako μ osobników wybranych z $P \cup R$.
5. Jeśli jest spełniony warunek stopu, zwróć wynik jako najlepszy element P ;
w przeciwnym razie wróć do punktu 2.


Presja selekcyjna, eksploracja, eksploatacja



- Algorytm: $(\mu + \lambda)$
- Populacja $P \cup R$:
- Presja selekcyjna: preferencja dla lepiej przystosowanych - słaba / silna
- Eksploracja = poszukiwanie max. globalnego
- Eksploatacja = poszukiwanie max. lokalnego

Nowoczesne algorytmy ewolucyjne

- Cel:
 - Nowi członkowie populacji są losowani z tego samego rozkładu o dostosowującej się macierzy kowariancji
- Problem:
 - Jak to osiągnąć?



Algorytm CMA-ES

Covariance Matrix Adaptation Evolution Strategy

```
ustal  $\lambda$   
zainicjuj  $m, \sigma, C = I, p_\sigma = 0, p_C = 0$   
while nie koniec :  
    for  $i = 1 \dots \lambda$  :  
         $x_i \sim N(m, \sigma^2 C)$   
    przesortuj  $x_1 \dots x_\lambda$  według  $f(x_i)$  malejąco  
     $m' \leftarrow m$   
     $m \leftarrow \text{update\_m}(x_i, \dots, x_\lambda)$   
     $p_\sigma \leftarrow \text{update\_p}_\sigma(p_\sigma, \sigma^{-1} C^{-1/2} (m - m'))$   
     $p_C \leftarrow \text{update\_p}_C(p_C, \sigma^{-1} (m - m'), \|p_\sigma\|)$   
     $C \leftarrow \text{update\_C}(C, p_C, (x_1 - m')/\sigma, \dots, (x_\lambda - m')/\sigma)$   
     $\sigma \leftarrow \text{update\_}\sigma(\sigma, \|p_\sigma\|)$   
return  $m$  lub  $x_1$ 
```

Algorytm CMA-ES

m – środek chmury punktów

update_m

$$\begin{aligned} m &= \sum_{i=1}^{\lambda} w_i x_i \\ &= m' + \sum_{i=1}^{\lambda} w_i (x_i - m') \end{aligned}$$

$$w_1 \geq w_2 \geq \dots \geq w_{\lambda} \geq 0$$

$$\sum_{i=1}^{\lambda} w_i = 1$$

$$\sum_{i=1}^{\lambda} w_i^2 \approx 4/\lambda$$

typowo $w_i = 0$ dla $i > \lambda/2$

ustal λ

zainicjuj $m, \sigma, C = I, p_{\sigma} = 0, p_C = 0$

while *nie koniec*:

for $i = 1 \dots \lambda$:

$$x_i \sim N(m, \sigma^2 C)$$

 przesortuj $x_1 \dots x_{\lambda}$ według $f(x_i)$ malejąco

$$m' = m$$

$$m \leftarrow \text{update_m}(x_i, \dots, x_{\lambda})$$

$$p_{\sigma} \leftarrow \text{update_p}_{\sigma}(p_{\sigma}, \sigma^{-1} C^{-1/2} (m - m'))$$

$$p_C \leftarrow \text{update_p}_C(p_C, \sigma^{-1} (m - m'), \|p_{\sigma}\|)$$

$$C \leftarrow \text{update_C}(C, p_C, (x_1 - m')/\sigma, \dots, (x_{\lambda} - m')/\sigma)$$

$$\sigma \leftarrow \text{update_}\sigma(\sigma, \|p_{\sigma}\|)$$

return m lub x_1

Algorytm CMA-ES

σ – skala chmury punktów

p_σ – ścieżka zmian σ

update_ p_σ

update_ σ

$$p_\sigma \leftarrow (1 - \beta_\sigma) p_\sigma + \sqrt{1 - (1 - \beta_\sigma)^2} \sqrt{\bar{W}} C^{-1/2} \frac{m - m'}{\sigma}$$

$$\sigma \leftarrow \sigma \exp \left(\frac{\beta_\sigma}{d_\sigma} \left(\frac{\|p_\sigma\|}{E \|N(0, I)\|} - 1 \right) \right)$$

$$n = \dim(x_i)$$

$$\beta_\sigma \approx 3/n$$

$$W = \left(\sum_{i=1}^{\lambda} w_i^2 \right)^{-1}$$

$$d_\sigma \approx 1$$

ustal λ

zainicjuj $m, \sigma, C = I, p_\sigma = 0, p_C = 0$

while *nie koniec*:

for $i = 1 \dots \lambda$:

$$x_i \sim N(m, \sigma^2 C)$$

 przesortuj $x_1 \dots x_\lambda$ według $f(x_i)$ malejąco

$$m' = m$$

$$m \leftarrow \text{update_m}(x_i, \dots, x_\lambda)$$

$$p_\sigma \leftarrow \text{update_p}_\sigma(p_\sigma, \sigma^{-1} C^{-1/2} (m - m'))$$

$$p_C \leftarrow \text{update_p}_C(p_C, \sigma^{-1} (m - m'), \|p_\sigma\|)$$

$$C \leftarrow \text{update_C}(C, p_C, (x_1 - m')/\sigma, \dots, (x_\lambda - m')/\sigma)$$

$$\sigma \leftarrow \text{update_}\sigma(\sigma, \|p_\sigma\|)$$

return m lub x_1

Algorytm CMA-ES

C – macierz kowariancji chmury punktów

p_C – ścieżka zmian C

update_p_C

update_C

$$p_C \leftarrow (1 - \beta_C) p_C + \mathbf{1}_{[0, 1.5\sqrt{n}]}(\|p_\sigma\|) \sqrt{1 - (1 - \beta_C)^2} \sqrt{W} \frac{m - m'}{\sigma}$$

$$C \leftarrow (1 - \beta_1 - \beta_W + \beta_S) C + \beta_1 p_C p_C^T + \beta_W \sum_{i=1}^{\lambda} w_i \frac{x_i - m}{\sigma} \left(\frac{x_i - m}{\sigma} \right)^T$$

$$n = \dim(x_i)$$

$$\beta_C \approx 4/n$$

$$\mathbf{1}_{[0, 1.5\sqrt{n}]}(\|p_\sigma\|) = 1 \text{ jeśli } \|p_\sigma\| \in [0, 1.5\sqrt{n}] \quad (\text{inaczej } = 0)$$

$$\beta_S = (1 - \mathbf{1}_{[0, 1.5\sqrt{n}]}(\|p_\sigma\|)) \beta_1 \beta_C (2 - \beta_C)$$

$$\beta_1 \approx 2/n^2$$

$$\beta_M \approx W/n^2, \quad W = \left(\sum_{i=1}^{\lambda} w_i^2 \right)^{-1}$$

ustal λ

inicjacja $m, \sigma, C = I, p_\sigma = 0, p_C = 0$

while *nie koniec*:

for $i = 1 \dots \lambda$:

$$x_i \sim N(m, \sigma^2 C)$$

 przesortuj $x_1 \dots x_\lambda$ według $f(x_i)$ malejąco

$m' = m$

$$m \leftarrow \text{update_m}(x_i, \dots, x_\lambda)$$

$$p_\sigma \leftarrow \text{update_p}_\sigma(p_\sigma, \sigma^{-1} C^{-1/2} (m - m'))$$

$$p_C \leftarrow \text{update_p}_C(p_C, \sigma^{-1} (m - m'), \|p_\sigma\|)$$


$$C \leftarrow \text{update_C}(C, p_C, (x_1 - m')/\sigma, \dots, (x_\lambda - m')/\sigma)$$

$$\sigma \leftarrow \text{update_}\sigma(\sigma, \|p_\sigma\|)$$

return m lub x_1

Ewolucja różnicowa

- μ osobników w populacji
- Nowe osobniki tworzone formułami typu
$$\text{nowy} = x + F(y - z)$$
 x, y, z – osobniki
 F – współczynnik
- Zostaje lepszy
z pary:
stary,
nowy



Ewolucja różnicowa – algorytm

ustal λ

wylosuj λ osobników z przeszukiwanej przestrzeni

dopóki *nie koniec*:

for $i=1 \dots \lambda$:

wylosuj kilka osobników do reprodukcji

reprodukuj x'_i z tych osobników

$x'_i \leftarrow \text{krzyżowanie}(x'_i, x_i)$

jeśli $f(x'_i) > f(x_i)$:

 W następnym pokoleniu x'_i zastępuje x_i

zwróć x_{best}

DE – reprodukcja

j_1, j_2, \dots są losowane z $\{1, \dots, \lambda\}$

Różne strategie:

$$\text{DE/rand/1} : x'_i = x_{j_1} + F \cdot (x_{j_2} - x_{j_3})$$

$$\text{DE/rand/2} : x'_i = x_{j_1} + F \cdot (x_{j_2} - x_{j_3} + x_{j_4} - x_{j_5})$$

$$\text{DE/best/1} : x'_i = x_{best} + F \cdot (x_{j_1} - x_{j_2})$$

$$\text{DE/best/2} : x'_i = x_{best} + F \cdot (x_{j_1} - x_{j_2} + x_{j_3} - x_{j_4})$$

$$\text{DE/rand-to-best/2} : x'_i = x_i + F \cdot (x_{best} - x_i + x_{j_1} - x_{j_2})$$

DE – krzyżowanie

Wariant dwumianowy (bin):

Dla każdego $k=1..dim(x)$:

jeśli liczba losowa z $[0,1] < C_r$:

$$x'[k] \leftarrow x[k]$$

w przeciwnym razie:

$$x'[k] \leftarrow x'[k]$$

Wariant wykładniczy (exp):

Dla kolejnego $k=1..dim(x)$:

jeśli liczba losowa z $[0,1] < C_r$:

$$x'[k] \leftarrow x[k]$$

w przeciwnym razie dla pozostałych k :

$$x'[k] \leftarrow x'[k]$$


Strategie są określane jako: DE/best/1/bin, DE/rand/1/exp itd.

Uogólniony algorytm ewolucyjny

- Cel: znalezienie najlepszego elementu dziedziny = osobnika
- Osobniki tworzą populację
- Nowe osobniki powstają przez krzyżowanie i mutację już istniejących

Algorytmy genetyczne: motywacja

- Osobnik czyli *fenotyp*, kodowany przez pewien projekt – *genotyp*
- Przedmiotem krzyżowania i mutacji są genotypy
- Motywacja: prawie wszystko daje się zapisać przez sekwencje bitów



Algorytmy genetyczne: terminologia


- *fenotyp* – osobnik
- *genotyp* – kod osobnika
- *gen* – pojedynczy element kodu
- *locus* – pozycja w genotypie
- *chromosom* – zgrupowanie pozycji, na których geny kodują jakąś niezależną cechę fenotypu

Ogólny algorytm genetyczny


1. Wygeneruj populację początkową genotypów P
2. Reprodukuj z par z P zbiór genotypów R przez zastosowanie krzyżowania a potem mutacji
3. Wybierz z $P \cup R$ nową populację P tworząc z każdego genotypu osobnika i oceniając go
4. Jeśli nie jest spełniony warunek stopu, wróć do punktu 2, w przeciwnym razie zwróć fenotyp najlepszego osobnika z P

Genotypu binarne: krzyżowanie

1. Krzyżowanie
jednopunktowe



2. Krzyżowanie
kilkupunktowe



3. Krzyżowanie
równomierne:
na danym locus
gen od losowego
rodzica

1. Wygeneruj populację początkową P
2. Reprodukuj z par z P zbiór genotypów R przez zastosowanie krzyżowania a potem mutacji
3. Wybierz z $P \cup R$ nową populację P
4. Jeśli nie jest spełniony warunek stopu, wróć do punktu 2.

Genotypy binarne: mutacja

1. Z zadanyim prawdopodobieństwem p_m podlega jej każdy gen w genotypie
2. p_m powinno być małe; np. takie aby mutacji podlegał co 10-ty genotyp

Przykład rozróżnienia

- Problem komiwojażera
- Podejście ewolucyjne „klasyczne”
 - osobnikami są permutacje - na nich przeprowadzane są krzyżowanie i mutacja
- Podejście genetyczne
 - permutacje są reprezentowane przez wektory binarne - na nich przeprowadzane są krzyżowanie i mutacja

Co jeszcze w ramach tego podejścia

- Metody kodowania
- Algorytmy memetyczne:
ewolucja + przeszukiwanie lokalne
- Programowanie ewolucyjne/genetyczne
- Hybrydy z innymi narzędziami sztucznej inteligencji, np. sieciami neuronowymi